



Business Intelligence: del dato a la decisión

Manual del curso ADGG102PO · Business Intelligence

Material para el alumno

Basado en el caso Rueda Libre · Sesiones 1 a 8

Agosto de 2026

Sobre este manual

Este documento recoge, ordena y desarrolla el contenido de las ocho sesiones del curso de Business Intelligence. No es una transcripción de las clases: es el material de referencia que queda cuando el curso termina.

Todo lo que se explica aquí está construido sobre un mismo caso —una cadena de tiendas de bicicletas llamada **Rueda Libre**— que a lo largo del curso pasa de tener seis fuentes de datos incompatibles y un informe mensual en hoja de cálculo a disponer de un modelo analítico, un cuadro de mando y un pronóstico de demanda. Los problemas que aparecen en el caso no son inventados: son los que aparecen en todos los proyectos de BI, siempre en el mismo orden.

La idea que sostiene todo el curso

Business Intelligence no consiste en hacer gráficos. Consiste en transformar datos en evidencia para tomar decisiones. Un gráfico bonito construido sobre un indicador mal definido no es inteligencia de negocio: es una forma más rápida de equivocarse.

Si al terminar de leer este manual sólo se retiene una idea, que sea ésta: **tener datos no es lo mismo que entender los datos**. Todas las técnicas que se explican en las páginas siguientes —las escalas de medida, el almacén, el modelo dimensional, los indicadores, los pronósticos— existen para cerrar esa distancia.

Cómo está organizado

El manual tiene dos partes y cinco apéndices.

La Parte I explica los fundamentos, organizados por materia. Cada capítulo se puede leer por separado y sirve para consultar un concepto concreto meses después: qué diferencia hay entre una escala ordinal y una cuantitativa, por qué un porcentaje no se puede promediar, qué es exactamente el grano de una tabla de hechos.

La Parte II reconstruye el caso Rueda Libre paso a paso, desde el primer informe hasta el pronóstico. Aquí no se explican conceptos nuevos: se muestra cómo se aplicaron, en qué orden, qué problema resolvía cada decisión y qué se rompió por el camino. Es la parte que da sentido a la primera.

Los apéndices contienen el mapa del temario oficial, un glosario, una referencia rápida de indicadores y su interpretación, las soluciones de los ejercicios y una lista de errores estadísticos que circulan como verdades.

Cada capítulo termina con **ejercicios propuestos** sobre el propio caso. Las soluciones comentadas están en el Apéndice D. Hacerlos es la diferencia entre haber leído el manual y haber aprendido algo.

Convenciones tipográficas

A lo largo del texto se usan tres marcas:

Las citas enmarcadas recogen las ideas centrales del curso, tal y como se formularon en clase.

Los bloques monoespaciados muestran datos, fórmulas o resultados reales del caso. Cuando se muestra una versión simplificada para explicar un concepto, se indica expresamente.

⚠ Los avisos señalan errores frecuentes, trampas conocidas y puntos donde la teoría y la práctica no coinciden.

Los dos personajes

Dos figuras recorren el manual de principio a fin. No son un adorno: cada una representa un problema estadístico concreto que reaparece en cada capítulo.

Manolo lleva el taller de la tienda central de Rueda Libre. Repara bicicletas de carretera, pero también acepta trabajos que nadie más acepta: restauraciones completas que le llevan tres semanas. Manolo es el **valor atípico**. Infla la media del tiempo de reparación, descuadra el margen del taller, rompe la carga nocturna cuando teclea el modelo de bicicleta a mano y arruina el pronóstico de demanda cada vez que le entra un encargo grande.

Gertru es la responsable de datos de la cadena. Es el contrapeso: el caso extremo por el lado contrario, la que pregunta de dónde sale cada cifra y la que recuerda —cada vez que alguien quiere borrar a Manolo del conjunto de datos— que un valor atípico no es necesariamente un error.

Todo el curso se puede resumir en una pregunta: ¿este dato es un Manolo, o es la realidad?

El caso: Rueda Libre

Rueda Libre es una cadena de doce tiendas de bicicletas repartidas por España. Vende bicicletas, componentes y accesorios, y cada tienda tiene un taller de reparación. Desde hace tres años tiene además una tienda en línea.

Sus sistemas, tal y como estaban al empezar el curso:

TPV de tienda	Un terminal por tienda. Ventas, líneas de ticket, forma de pago.
Gestor de taller	Órdenes de reparación: entrada, salida, piezas, mano de obra.
Tienda en línea	Pedidos web, con su propio catálogo y sus propios códigos.
Fichero de clientes	Alta manual en cada tienda. Sin control de duplicados.
ERP de compras	Proveedores, stock, precio de coste.
Objetivos.xlsx	Objetivos mensuales por tienda. Lo mantiene una persona a mano.

Seis fuentes, cuatro definiciones distintas de «venta», tres catálogos de producto que no casan y un cliente que puede estar dado de alta cinco veces. Es un punto de partida absolutamente normal.

La pregunta que abre el proyecto la formula la dirección en la primera reunión:

«¿Por qué la tienda de Valencia vende más que la de Zaragoza si son del mismo tamaño?»

Responderla bien ocupa las ocho sesiones del curso.

Índice

Parte I · Fundamentos

1. **Qué es Business Intelligence** Dato frente a información · La pirámide organizacional · Los cuatro niveles de analítica · Las familias de herramientas · El recorrido completo del dato a la decisión
2. **Escalas de medida: cómo está medido el dato** Cualitativo y cuantitativo · Escala nominal · Escala ordinal · Escala cuantitativa · Discreta y continua · De razón y de intervalo · La escalera de medida · Por qué esto decide todo lo demás
3. **La calidad del dato** Las seis dimensiones de la calidad · Valores nulos · Duplicados · Codificaciones inconsistentes · Unidades y divisas · Fechas · Granularidades distintas · El coste de no limpiar
4. **Resumir: frecuencias y tendencia central** Frecuencia absoluta, relativa y acumulada · Tablas de frecuencias · Agrupación en intervalos · Moda · Mediana · Media · Cuando la media engaña · Robusto y suficiente
5. **Dispersión, posición y forma** Por qué una media sola no dice nada · Rango · Varianza · Desviación típica · Cómo se interpreta · Cuartiles, deciles y percentiles · Rango intercuartílico · Simetría y asimetría · Valores atípicos · El diagrama de caja y bigotes
6. **Sistemas operacionales y sistemas analíticos** Sistemas OLTP · Normalización · OLTP frente a OLAP · El almacén de datos · Características y ventajas · Datamarts · Enfoques descendente y ascendente · Capas e historificación
7. **Procesos ETL** Extracción · Transformación · Carga · Carga completa e incremental · Captura de cambios · Conformado de dimensiones · ETL frente a ELT · Orquestación · Gobierno del dato
8. **El modelo dimensional** Hechos y dimensiones · La granularidad · Esquema en estrella y en copo de nieve · Jerarquías · La dimensión Fecha · Métricas aditivas, semiaditivas y no aditivas · La media ponderada · Cubos · Drill-down y drill-up · ROLAP, MOLAP y HOLAP
9. **Analizar: relaciones y segmentación** Análisis exploratorio · Segmentación · Comparar poblaciones equivalentes · La paradoja de Simpson · Correlación · Correlación y causalidad · Variables de confusión
10. **Minería de datos** Qué es y qué no es · Clasificación · Regresión · Agrupamiento · Reglas de asociación · Detección de anomalías · El proceso de minería · CRISP-DM · Sobreajuste y validación
11. **Indicadores, informes y cuadros de mando** Métrica y KPI · La definición operativa · Absolutos y relativos · Ratios y tasas · La media de medias · El contexto · Informes · Consultas · Alertas · Diseño de un cuadro de mando · Visualización honesta

12. **Series temporales y pronósticos** Descripción frente a predicción · Tendencia, estacionalidad, ciclo y ruido · Comparaciones entre períodos · Medias móviles · Modelos sencillos de pronóstico · Incertidumbre · Tamaño de muestra · Riesgos del pronóstico automatizado
13. **La gestión de un proyecto de BI** Por qué no es un proyecto de desarrollo · Las fases · Roles · Planificación · Los diez riesgos típicos · Validación y evolución

Parte II · El caso Rueda Libre, paso a paso

14. **Versión 1 — El informe mensual en hoja de cálculo**
15. **Versión 2 — Unificar las fuentes**
16. **Versión 3 — El modelo dimensional**
17. **Versión 4 — El cuadro de mando**
18. **Versión 5 — Del descriptivo al predictivo**
19. **Balance de la evolución**

Apéndices

- **A.** El temario oficial, punto por punto
 - **B.** Glosario de términos
 - **C.** Referencia rápida de indicadores
 - **D.** Soluciones de los ejercicios
 - **E.** Errores que circulan como verdades
-

Parte I · Fundamentos

1. Qué es Business Intelligence

Antes de montar nada conviene entender para qué sirve lo que se va a montar. La mayor parte de los proyectos de BI que fracasan no fracasan por la tecnología: fracasan porque nadie se detuvo a preguntar qué decisión iba a mejorar el resultado.

1.1. Tener datos no es entenderlos

Imagínese que alguien quiere saber cómo se mueven los salarios en una empresa de cinco mil empleados y le entregan las cinco mil nóminas. Un paquete de quinientas hojas ocupa unos cinco centímetros: son cincuenta centímetros de papel. Medio metro de datos.

Ahí está toda la verdad. No hay más información disponible sobre la cuestión: esa es la fuente. Y sin embargo, alguien podría pasarse una semana leyendo esas cinco mil nóminas y, al terminar, seguiría sin saber cómo se mueven los salarios en esa empresa. Recordaría anecdóticamente el más alto y el más bajo. Nada más.

Tener datos y entender los datos son dos cosas distintas. Toda la estadística descriptiva —y por extensión todo el Business Intelligence— existe para cubrir la distancia entre una y otra.

El problema no es de acceso al dato. Es de capacidad de proceso: un cerebro humano no puede sostener cinco mil valores a la vez. Lo que hace falta es un mecanismo para **resumir** que no destruya lo esencial por el camino. Y ahí está la dificultad: todo resumen pierde información, y la habilidad consiste en perder la que no importa.

1.2. Dato e información no son lo mismo

Un dato es un valor registrado. La información es lo que ese valor permite concluir, y casi siempre es mucho más de lo que el dato dice literalmente.

Supóngase que se conoce el peso de una persona de altura promedio: 140 kg. El dato son los 140 kg. La información que transporta es otra cosa:

- Con altísima probabilidad, la persona tiene más de veinte años.
- Es probable que tenga problemas de salud asociados al sobrepeso.
- Es probable que su alimentación no sea equilibrada.
- Es probable que no haga ejercicio con regularidad.
- Su talla de ropa es 3XL o superior.

Ninguna de esas conclusiones está escrita en el dato. Todas se derivan de él. Y todas pueden ser falsas: la persona podría ser un culturista con una masa muscular enorme. Con más datos —porcentaje de

grasa corporal, nivel de actividad física— las estimaciones mejorarían.

Esa es exactamente la mecánica de un proyecto de BI: se recogen datos concretos sobre un fenómeno para poder afirmar cosas que los datos no dicen literalmente.

⚠ El riesgo también es el mismo: cuanto más lejos se llega en la inferencia, más fácil es equivocarse. Un cuadro de mando que muestra datos es inofensivo. Uno que sugiere conclusiones sin decir con qué confianza, no.

1.3. Qué es y qué no es Business Intelligence

Business Intelligence es el conjunto de procesos, arquitecturas y técnicas que convierten datos en bruto en información útil para la toma de decisiones de negocio.


Conviene delimitarlo por contraste:

No es	Es
Hacer gráficos bonitos	Definir qué se mide y por qué
Sacar un listado de un sistema	Integrar varias fuentes en una versión única
Una herramienta concreta	Una capa entre los sistemas operativos y las personas
Un proyecto que termina	Un servicio que se mantiene y evoluciona
Analítica avanzada	La base sobre la que la analítica avanzada se sostiene

La confusión más frecuente es la primera. Una organización puede tener veinte cuadros de mando y ninguna inteligencia de negocio, si esos cuadros no responden a preguntas que alguien se esté haciendo de verdad.

1.4. La pirámide organizacional

Las decisiones no se toman igual en todos los niveles de una organización, y por tanto no necesitan la misma información.



Nivel	Pregunta típica	Granularidad	Frecuencia	Formato
Operativo	¿Qué reparaciones tengo hoy sin cerrar?	Máximo detalle: el registro individual	Continua	Listado, alerta
Táctico	¿Cómo va mi tienda respecto al objetivo del trimestre?	Agregado por tienda y mes	Semanal o mensual	Cuadro de mando
Estratégico	¿Debemos abrir tienda en Bilbao?	Muy agregado, con series largas	Trimestral o anual	Informe con escenarios

Este cuadro tiene una consecuencia práctica inmediata: **la misma cifra no sirve para los tres niveles**. Un director general al que se le entrega el detalle de cada ticket no puede decidir nada, y un encargado de tienda al que se le entrega únicamente el acumulado anual tampoco.

⚠ El error más frecuente en cuadros de mando corporativos es diseñar uno solo y repartirlo hacia arriba y hacia abajo. Termina siendo demasiado agregado para quien opera y demasiado detallado para quien dirige.

1.5. Los cuatro niveles de analítica

Es el mapa que ordena todo el curso, y también la escalera por la que se sube.

DESCRIPTIVA	¿Qué ha pasado?	Informes, cuadros de mando, KPIs
↓		
DIAGNÓSTICA	¿Por qué ha pasado?	Segmentación, correlación, drill-down
↓		
PREDICTIVA	¿Qué puede pasar?	Series temporales, modelos, pronósticos
↓		
PRESCRIPTIVA	¿Qué debería hacer?	Optimización, simulación, reglas

Tres observaciones que ahorran disgustos:

1. **No se puede saltar escalones.** Una organización que no sabe cuánto vendió el mes pasado — porque cada sistema da una cifra distinta— no está en condiciones de predecir cuánto venderá el mes que viene.
2. **El valor sube y la fiabilidad baja.** Cuanto más arriba, más útil es la respuesta y más incierta.
3. **La mayor parte del retorno está en los dos primeros escalones.** Buena parte de los proyectos que se venden como predictivos habrían dado más valor arreglando el descriptivo.

1.6. Las familias de herramientas

El mercado de BI cambia cada pocos años; las categorías no. Conviene conocer las familias y no las marcas, porque las marcas de dentro de cinco años serán otras.

Familia	Qué hace	Ejemplos actuales
Integración	Extraer, transformar y cargar datos	Talend, Pentaho, Azure Data Factory, dbt
Almacenamiento analítico	Guardar el histórico integrado	Snowflake, BigQuery, Redshift, SQL Server
Modelado semántico	Definir métricas y jerarquías una sola vez	Analysis Services, modelos tabulares, dbt metrics
Visualización	Informes y cuadros de mando	Power BI, Tableau, Looker, Qlik
Analítica avanzada	Modelos estadísticos y de aprendizaje	Python, R, servicios gestionados
Gobierno	Catálogo, linaje, calidad, permisos	Purview, Collibra, Amundsen

La herramienta es la última decisión de un proyecto de BI, no la primera. Cuando una organización empieza eligiendo herramienta, casi siempre acaba adaptando sus preguntas a lo que la herramienta sabe responder.

1.7. El recorrido completo

Este esquema aparece en todas las sesiones del curso. Cada capítulo del manual desarrolla uno o dos de sus eslabones.

Pregunta de negocio	¿Qué decisión hay que tomar?	cap. 1, 13
↓		
Datos	¿Qué fuentes existen?	cap. 6, 7
↓		
Calidad del dato	¿Se puede confiar en ellas?	cap. 3
↓		
Análisis estadístico	¿Qué dicen realmente?	cap. 4, 5, 9
↓		
Modelo / indicador	¿Cómo se resume sin mentir?	cap. 8, 11
↓		
Visualización	¿Cómo se muestra?	cap. 11
↓		
Interpretación	¿Qué se puede concluir?	cap. 5, 9, 12
↓		
Decisión	¿Qué se hace distinto mañana?	cap. 13

La versión reducida que circula en muchas organizaciones —*datos* → *ETL* → *almacén* → *cuadro de mando*— se salta tres eslabones: la pregunta, la calidad y la interpretación. Son precisamente los tres que determinan si el cuadro de mando dice la verdad.

1.8. Las nueve preguntas

Se presentan aquí y se aplican en todos los ejercicios del manual. Son la herramienta de trabajo más útil del curso, y no requieren ninguna tecnología.

1. ¿Qué estoy midiendo exactamente?
2. ¿De dónde viene el dato?
3. ¿Es comparable con aquello con lo que lo estoy comparando?
4. ¿Qué distribución tiene?
5. ¿Es representativa la media?
6. ¿Hay valores extremos y qué significan?
7. ¿Estoy comparando poblaciones equivalentes?
8. ¿Existe realmente una tendencia?
9. ¿Qué decisión tomaría con este dato?

Ejercicios del capítulo 1

1.1. La dirección de Rueda Libre pregunta: «¿Por qué la tienda de Valencia vende más que la de Zaragoza si son del mismo tamaño?» Reformula la pregunta en términos que se puedan medir. ¿Cuántas preguntas distintas hay realmente escondidas dentro?

1.2. Clasifica cada una de estas peticiones según el nivel de la pirámide al que pertenece, y di qué granularidad de dato necesita cada una: (a) el listado de reparaciones pendientes de recoger; (b) el margen por familia de producto y trimestre; (c) la evolución de la cuota de mercado en los últimos cinco años.

1.3. Una consultora propone a Rueda Libre un proyecto de predicción de demanda con aprendizaje automático. Al preguntar, se descubre que el TPV y la tienda en línea dan cifras de venta distintas para el mismo día y nadie sabe cuál es la buena. ¿Qué recomendarías y por qué? Sitúa la respuesta en la escalera de los cuatro niveles de analítica.

1.4. Toma un indicador que veas en tu trabajo. Aplícale las nueve preguntas. ¿Cuántas puedes responder sin consultar a nadie?

2. Escalas de medida: cómo está medido el dato

Este capítulo parece elemental y no lo es. Todas las técnicas estadísticas, todos los gráficos y buena parte de las decisiones de modelado dependen de la escala en la que está medido el dato. Saltárselo es la causa número uno de cuadros de mando conceptualmente falsos.

2.1. La distinción fundamental

La estadística distingue entre datos **cualitativos** y **cuantitativos**. Más exactamente: entre datos *medidos de forma* cualitativa y *medidos de forma* cuantitativa, porque lo que se clasifica no es el dato sino la manera de representarlo.

La diferencia está en una sola cosa: **si el dato representa una cantidad o no**.

Y aquí llega el punto que casi nadie tiene claro. *Cuantitativo* viene de *cantidad*, y **un número no es una cantidad**. Un número de teléfono está compuesto de cifras y no es una cantidad. Un código postal tampoco. Un número de cliente tampoco. Un código de artículo tampoco.

Para que algo sea una cantidad tiene que tener una **unidad de medida** asociada, que diga qué se está contando.

140 kg es una cantidad: la unidad es el kilogramo. El código postal 28850 no lo es: no hay unidad. Y esto no es una sutileza académica; tiene una consecuencia inmediata en cualquier herramienta de BI, que verá una columna de números y ofrecerá sumarla.

⚠ Casi todas las herramientas de BI clasifican los datos por su **naturaleza técnica** —texto, número, fecha— y no por su escala de medida. Es responsabilidad de quien modela decidir cuáles de esos números son cantidades. Una herramienta que suma códigos postales no está fallando: está haciendo lo que se le ha pedido.

Las unidades no tienen que ser del Sistema Internacional. Son perfectamente válidas:

Número de hijos	unidad: hijos
Número de visitas	unidad: visitas
Número de reparaciones	unidad: reparaciones
Importe de venta	unidad: euros
Tiempo de reparación	unidad: horas

2.2. La escala nominal

Nominal viene de *nombre*. Medir en escala nominal es asignar un nombre —una palabra o una frase corta— a cada una de las formas que puede adoptar el dato.

Ejemplos en Rueda Libre:

Tipo de producto	bicicleta · componente · accesorio · ropa
Forma de pago	efectivo · tarjeta · financiación · transferencia
Tienda	Valencia · Zaragoza · Bilbao · ...
Canal	tienda física · web

Lo que una escala nominal permite es **clasificar**: agrupar los individuos según el valor del dato. «Las ventas de bicicleta a la izquierda, las de componente en el centro, las de accesorio a la derecha.» Nada más. No hay orden: no tiene sentido decir que *efectivo* va antes que *tarjeta*.

Con una variable nominal se puede calcular la frecuencia de cada categoría y la moda. No se puede calcular ni la mediana ni la media.

2.3. La escala ordinal

Considérese ahora el nivel de satisfacción de un cliente medido como *bajo*, *medio*, *alto*. Son tres palabras, tres categorías: sirven para clasificar, luego es una escala nominal.

Pero además esas palabras tienen un **orden implícito**. Alguien con satisfacción alta está más satisfecho que alguien con satisfacción media, y éste más que alguien con satisfacción baja. Eso permite algo que la escala nominal no permitía: **ordenar** a los individuos.

Por definición, toda escala ordinal es también una escala nominal. Lo que añade es la posibilidad de ordenar.

Ejemplos en Rueda Libre:

Prioridad de la reparación	baja · normal · urgente
Segmento de cliente	ocasional · habitual · premium
Valoración del servicio	1 a 5 estrellas
Nivel de stock	agotado · bajo · normal · exceso

Con una variable ordinal se pueden calcular frecuencias, moda, **mediana**, cuartiles y percentiles, y tienen sentido las frecuencias acumuladas. Sigue sin poderse calcular la media.

⚠ Ésta es la trampa más común de todo el capítulo. Una valoración de 1 a 5 estrellas está compuesta de números, pero es ordinal: no hay unidad de medida. La distancia entre 1 y 2 estrellas no es

necesariamente la misma que entre 4 y 5, y lo que para un cliente es un 3 para otro es un 4. Promediar valoraciones es una operación matemáticamente posible y conceptualmente discutible.

En la práctica todas las empresas del mundo promedian sus valoraciones. Lo que puede hacerse, sin declararle la guerra a la organización, es acompañar siempre esa media de la **distribución** —cuántos 1, cuántos 2, cuántos 5— o convertirla en un indicador construido a propósito, como el porcentaje de detractores y promotores. Una media de 3,5 puede venir de todo el mundo puntuando 3 y 4, o de la mitad puntuando 1 y la otra mitad 5. Son dos negocios completamente distintos.

2.4. La escala cuantitativa

Los datos cuantitativos son los que representan una cantidad y tienen unidad de medida. Esa unidad es lo que abre la puerta a las **operaciones matemáticas con sentido real**.

La distinción importa. Matemáticamente se pueden sumar dos códigos postales:

$$19200 + 28850 = 48050$$

El resultado es correcto y no significa nada. Lo mismo con los números de portal: vivir en el 17 y en el 25 no permite decir que entre los dos suman 42.

En cambio:

$$\begin{array}{ll} 2 \text{ hijos} + 3 \text{ hijos} = 5 \text{ hijos} & \text{ Tiene sentido} \\ 80 \text{ kg} - 70 \text{ kg} = 10 \text{ kg de diferencia} & \text{ Tiene sentido} \end{array}$$

La potencia de los datos cuantitativos no está en que sean números. Está en que las operaciones que se hagan con ellos siguen significando algo en el mundo real.

Los datos cuantitativos se clasifican de dos maneras distintas y complementarias.

Según la cantidad de valores posibles:

- **Discretos:** sólo admiten valores enteros. Número de reparaciones, unidades vendidas, número de visitas. Suelen tener un número reducido de valores distintos.
- **Continuos:** admiten cualquier valor dentro de un rango, decimales incluidos. Importe de venta, tiempo de reparación, peso de una bicicleta. Pueden tener infinitos valores.

Esta diferencia no es teórica: determina si se puede hacer una tabla de frecuencias directamente o hay que agrupar en intervalos, y si el gráfico adecuado es un diagrama de barras o un histograma.

Según dónde está el cero:

- **De razón:** el cero es absoluto y significa ausencia de la propiedad. No existen valores negativos. Importe de venta, unidades vendidas, tiempo de reparación, peso.
- **De intervalo:** el cero es arbitrario, fijado por convenio. Temperatura en grados Celsius, año de nacimiento, altitud sobre el nivel del mar.

La consecuencia es concreta. Con datos de razón se puede multiplicar y dividir; con datos de intervalo, no:

```
Familia A: 4 hijos · Familia B: 2 hijos
→ «A tiene el doble de hijos que B»          Correcto

Madrid: 30 °C · Oslo: 15 °C
→ «En Madrid hace el doble de calor que en Oslo»  Incorrecto
```

Se ve mejor llevándolo al extremo. Si en Oslo hiciera -15 °C , la razón sería $30 / -15 = -2$. ¿Menos el doble de calor? Matemáticamente hay un resultado; en la práctica no significa nada. El cero de la escala Celsius no es la ausencia de temperatura, es el punto de congelación del agua.

⚠ En un cuadro de mando esto aparece disfrazado. «El margen ha crecido un 200 %» es correcto si el margen es de razón y positivo. Si el margen del año anterior fue negativo, el porcentaje de variación deja de tener interpretación. Lo mismo con cualquier indicador que pueda cruzar el cero.

2.5. La escalera de medida

Se ha visto que toda escala ordinal es también nominal. Ahora conviene fijarse en algo más: **todo dato cuantitativo es también ordinal**.

Las etiquetas «0 reparaciones», «1 reparación», «2 reparaciones» son categorías con las que se puede clasificar. Y además tienen orden. Por tanto:

```
CUANTITATIVA > ORDINAL > NOMINAL
```

De lo que se derivan las dos reglas más útiles de todo el capítulo.

Primera: siempre se puede bajar de escala. Un dato cuantitativo puede tratarse como ordinal, y uno ordinal como nominal. La misma variable, medida de tres maneras:

```
Cuantitativa  Número de reparaciones al mes: 0, 1, 2, 3, 7, 12...
Ordinal       Volumen de taller: ninguno · bajo · medio · alto
Nominal       ¿Tiene actividad de taller?: sí / no
```

Agrupar una variable cuantitativa en intervalos no es más que eso: bajarla a una escala ordinal.

0 reparaciones	→ ninguno
1–2 reparaciones	→ bajo
3–5 reparaciones	→ medio
6 o más	→ alto

Segunda: nunca se puede subir. Sabiendo únicamente que una tienda «tiene actividad de taller» es imposible deducir si es baja o alta, y mucho menos el número exacto de reparaciones.

Esta asimetría es la razón de una regla práctica de diseño de almacenes: se guarda siempre el dato al máximo nivel de detalle disponible. Bajar de escala se puede hacer en cualquier momento; subir requiere volver a la fuente, si es que todavía existe.

2.6. Por qué esto decide todo lo demás

El resumen de las consecuencias, que se irán encontrando en los capítulos siguientes:

	Nominal	Ordinal	Cuantitativa
Frecuencias	Sí	Sí	Sí
Frecuencia acumulada	No tiene sentido	Sí	Sí
Moda	Sí	Sí	Sí
Mediana	No	Sí	Sí
Media	No	No	Sí
Cuartiles y percentiles	No	Sí	Sí
Desviación típica	No	No	Sí
Diagrama de barras / sectores	Sí	Sí	Sí (si discreta)
Histograma	No	No	Sí (si continua)
Caja y bigotes	No	Con cautela	Sí
En el modelo dimensional	Dimensión	Dimensión con orden	Hecho (métrica)

La última fila es la que conecta este capítulo con el 8, y merece leerse dos veces: **las dimensiones de un modelo analítico son variables nominales y ordinales; los hechos son variables cuantitativas.** Quien tenga clara la escala de medida de cada columna tiene ya medio modelo diseñado.

Ejercicios del capítulo 2

2.1. Clasifica la escala de medida de cada campo del TPV de Rueda Libre e indica si en el modelo analítico sería dimensión o hecho: `id_ticket` , `fecha` , `id_tienda` , `código_postal_cliente` , `forma_de_pago` , `unidades` , `importe` , `descuento_%` , `valoración_1_a_5` .

2.2. El director comercial pide «la media del código postal de los clientes para saber dónde abrir la próxima tienda». Explica por qué la petición no tiene sentido y propón dos formas correctas de responder a la necesidad que hay detrás.

2.3. La variable «tiempo de reparación» está en horas. Propón una agrupación en intervalos que resulte útil para el jefe de taller y otra distinta que resulte útil para la dirección. Justifica por qué no son la misma.

2.4. Rueda Libre mide la satisfacción con una escala de 1 a 10. La media es 7,2. ¿Qué información adicional pedirías antes de incluir ese 7,2 en el cuadro de mando de dirección? Escribe la petición en una frase.

2.5. Una tienda registra la temperatura media diaria para estudiar su efecto en las ventas. En enero fue de 5 °C y en julio de 25 °C. Un informe afirma: «en julio hizo cinco veces más calor que en enero». Corrige la afirmación y explica cómo habría que expresarla.

3. La calidad del dato

Los datos son como los ingredientes de una cocina. Si no se limpian, si no se retira lo que no sirve, si no se cortan como toca, el resultado no será bueno por mucho que la técnica de cocinado sea impecable.

El error más común de quien empieza en análisis de datos es lanzarse a aplicar técnicas sobre un conjunto que nadie ha revisado. Lo que se obtiene entonces no refleja la realidad: refleja los defectos del conjunto de datos.

En un proyecto de BI la preparación de los datos ocupa más tiempo que el análisis. Habitualmente entre el 60 % y el 80 % del esfuerzo total. Cualquier planificación que no lo contemple está mal hecha desde el primer día.

3.1. Las seis dimensiones de la calidad

Dimensión	Pregunta	Ejemplo de fallo en Rueda Libre
Exactitud	¿El valor es correcto?	El TPV de Bilbao lleva dos meses con la fecha del sistema mal
Completitud	¿Falta información?	El 18 % de los tickets no tiene cliente asociado
Consistencia	¿Las fuentes coinciden?	La web y el TPV dan cifras distintas de la misma venta
Puntualidad	¿Llega a tiempo?	El ERP vuelca el coste con un mes de retraso
Unicidad	¿Hay duplicados?	Un mismo cliente dado de alta cinco veces
Validez	¿Cumple las reglas?	Reparaciones con fecha de salida anterior a la de entrada

Ninguna de las seis se arregla en la capa de visualización. Todas se arreglan antes, en el proceso de carga, o no se arreglan.

3.2. Valores nulos

Un valor ausente no es un cero. Confundirlos es una de las formas más rápidas de falsear un indicador.

Tienda	Ventas	Objetivo	
Valencia	142.000	130.000	
Zaragoza	98.000	110.000	
Bilbao	NULL	120.000	← ¿No vendió nada, o no llegó el dato?

Si el nulo se trata como cero, la cadena aparece con un 30 % de desviación sobre objetivo que no es real. Si se excluye la fila, el total baja pero el porcentaje de cumplimiento sube. Las dos opciones son defendibles; lo que no es defendible es no saber cuál se ha aplicado.

Estrategias habituales, de menos a más intervención:

1. **Dejarlo como nulo y hacerlo visible.** Casi siempre la mejor opción en BI: el cuadro de mando muestra «sin dato» y quien lo lee sabe a qué atenerse.
2. **Excluir el registro.** Válido si los ausentes son pocos y no siguen un patrón.
3. **Imputar un valor.** Sustituirlo por la media, la mediana o el valor anterior. Útil en modelado, peligroso en reporting: se está inventando un dato.
4. **Excluir la variable entera.** Si falta el 70 % de los valores, esa columna no sirve para nada.

⚠ Antes de decidir, hay que preguntarse **por qué** falta. Si los tickets sin cliente son precisamente los de venta rápida en efectivo, la ausencia no es aleatoria: contiene información. Excluirlos sesgaría el análisis de tipos de venta.

3.3. Duplicados

Los duplicados exactos son fáciles: se detectan y se eliminan. Los peligrosos son los otros.

id	nombre	email	teléfono
1	Manuel Rodríguez	manolo@correo.es	666112233
2	Manolo Rodriguez	manolo@correo.es	666 11 22 33
3	M. Rodríguez Pérez	manolo@correo.es	+34666112233

Tres registros, una persona. El impacto no es cosmético: el número de clientes está inflado, la venta media por cliente está deflactada y cualquier segmentación por frecuencia de compra es falsa, porque las compras de Manolo están repartidas entre tres identidades.

La solución técnica se llama **deduplicación** y consiste en definir una regla de identidad —qué campos determinan que dos registros son la misma entidad— y normalizar antes de comparar. La solución organizativa se llama gobierno del dato, y consiste en que alguien sea responsable del maestro de clientes.

3.4. Codificaciones inconsistentes

El mismo concepto escrito de formas distintas en fuentes distintas.

TPV	Tienda en línea	ERP
"BICICLETA"	"Bici"	"BIC"
"COMPONENTE"	"Componentes"	"CMP"
"ACCESORIO"	"Accesorios"	"ACC"
"ROPA"	"Textil"	"TEX"

Si no se unifica, un cuadro de mando por familia de producto mostrará ocho categorías donde hay cuatro, y ninguna cifra cuadrará con ninguna otra. El proceso que arregla esto se llama **conformado** y se ve en el capítulo 7.

3.5. Unidades, divisas y escalas

Un número sin unidad no es un dato: es un número.

```

peso_bicicleta: 9.4      ¿kilogramos o libras?
importe:        1250     ¿euros o céntimos?
tiempo:         180      ¿minutos u horas?
descuento:      0.15     ¿15 % o 0,15 %?

```

El caso de los céntimos es especialmente frecuente porque muchos sistemas transaccionales guardan importes como enteros para evitar errores de redondeo. Si el proceso de carga no lo convierte, el cuadro de mando muestra ventas cien veces mayores de lo real y nadie se da cuenta hasta que un director pregunta por qué la cadena factura más que su sector entero.

⚠ El descuento como `0.15` frente a `15` es la trampa silenciosa: ambos valores son plausibles, ninguno da error, y el resultado se desvía un factor cien. La única defensa es una regla de validación en la carga que compruebe rangos esperados.

3.6. Fechas

Las fechas concentran una cantidad desproporcionada de errores.

- **Formato.** `03/04/2026` es 3 de abril en España y 4 de marzo en Estados Unidos.
- **Zona horaria.** Una venta en línea a las 00:30 puede caer en un día u otro según cómo se almacene. En un cierre mensual esto mueve cifras.
- **Fecha de qué.** Fecha del pedido, del cobro, de la entrega y de la contabilización son cuatro fechas distintas. Un informe de ventas por mes da resultados distintos según cuál se use, y las cuatro son «la fecha de la venta» para alguien de la organización.
- **Fechas imposibles.** `31/02`, fechas futuras, `01/01/1900` como marca de nulo.

Cuando dos informes de ventas no cuadran, en la mitad de los casos el problema no está en el importe: está en qué fecha se ha usado para asignar la venta a un mes.

3.7. Granularidades distintas

Es el problema de integración más difícil, porque no da ningún error: simplemente produce resultados equivocados.

TPV	una fila por LÍNEA de ticket
Tienda en línea	una fila por PEDIDO
ERP	una fila por ALBARÁN
Objetivos.xlsx	una fila por TIENDA y MES

Cruzar directamente el TPV con los objetivos multiplica las filas: cada línea de ticket se emparejaría con el objetivo mensual completo, y el objetivo aparecería sumado tantas veces como líneas haya. El resultado es un cumplimiento del 3 % que provoca una reunión de urgencia innecesaria.

La regla es: **antes de cruzar dos conjuntos de datos, hay que saber decir en voz alta qué es una fila en cada uno**. Si no coinciden, hay que agregar uno de los dos hasta el grano común, y hacerlo explícitamente.

3.8. El coste de no limpiar

Se resume en una frase que conviene repetir en la reunión de arranque de cualquier proyecto:

Un dato malo en un sistema operativo afecta a una transacción. El mismo dato malo en un almacén analítico afecta a todas las decisiones que se tomen con él.

Y en una consecuencia práctica: el sitio donde se arregla la calidad del dato es la **fuentes**, no el proceso de carga. Un proceso de carga que corrige errores sistemáticos está ocultando un problema que seguirá creciendo. Lo correcto es corregir en origen y usar la carga como red de seguridad y como detector.

Ejercicios del capítulo 3

3.1. En el conjunto de reparaciones de Rueda Libre hay 40 registros con fecha de salida anterior a la de entrada. ¿A qué dimensión de la calidad afecta? Propón tres causas posibles y qué harías con esos registros en cada caso.

3.2. El 18 % de los tickets no tiene cliente asociado. La dirección quiere el indicador «venta media por cliente». Explica qué tres valores distintos podría tener ese indicador según cómo se traten los nulos, y cuál publicarías.

3.3. Se detecta que el TPV guarda los importes en céntimos y la tienda en línea en euros. Nadie se dio cuenta durante dos meses. ¿Qué indicadores del cuadro de mando estuvieron mal y cuáles no? Justifica por qué algunos se salvaron.

3.4. Diseña tres reglas de validación automática que hubieran detectado, en la carga, los errores de los ejercicios anteriores.

3.5. El fichero `Objetivos.xlsx` lo mantiene una persona a mano y a veces lo actualiza después del cierre. ¿A qué dimensión de la calidad afecta? Propón una solución que no dependa de la buena voluntad de esa persona.

4. Resumir: frecuencias y tendencia central

Vuelta al problema de las cinco mil nóminas. Hace falta un mecanismo para reducir el volumen de información hasta hacerlo manejable. La estadística ofrece dos familias: las tablas de frecuencias y los indicadores.

4.1. El concepto de frecuencia

Frecuencia es una palabra de uso cotidiano: cuántas veces ocurre algo. En estadística significa exactamente eso, aplicado a los datos: **cuántos individuos comparten un mismo valor**.

Para poder calcular una frecuencia hace falta poder clasificar. Y clasificar es justo lo que permite una escala nominal. Como toda escala ordinal y toda escala cuantitativa son también nominales, **a cualquier variable se le pueden calcular frecuencias**. Es la única técnica del manual de la que se puede decir eso.

4.2. La tabla de frecuencias

Es la representación básica. Ventas de Rueda Libre por familia de producto en un mes:

Familia	Frecuencia absoluta
Bicicleta	310
Componente	1.240
Accesorio	890
Ropa	260
Total	2.700

La **frecuencia absoluta** es el número de veces que aparece cada categoría.

La **frecuencia relativa** es la proporción sobre el total, normalmente expresada en porcentaje: frecuencia absoluta dividida entre el total, por cien.

Familia	Absoluta	Relativa
Bicicleta	310	$310/2.700 \times 100 = 11,5 \%$
Componente	1.240	45,9 %
Accesorio	890	33,0 %
Ropa	260	9,6 %
Total	2.700	100 %

La relativa es más útil cuando lo que interesa es el peso de cada categoría y no la cifra bruta, y es imprescindible para comparar dos períodos o dos tiendas de tamaño distinto.

4.3. La frecuencia acumulada

Cuando la variable está medida **al menos en escala ordinal**, se puede calcular la frecuencia acumulada: la suma de las frecuencias de todas las categorías anteriores a una dada, más la propia.

Tiempo de reparación en el taller, agrupado en intervalos:

Tiempo (horas)	Absoluta	Relativa	Acum. absoluta	Acum. relativa
0 – 4	420	42 %	420	42 %
5 – 8	310	31 %	730	73 %
9 – 24	160	16 %	890	89 %
25 – 72	80	8 %	970	97 %
más de 72	30	3 %	1.000	100 %

La acumulada permite afirmaciones que ninguna otra columna permite:

- El 73 % de las reparaciones se resuelven en 8 horas o menos.
- 270 reparaciones tardaron más de 8 horas.
- El 3 % tardó más de tres días. Ésas son las de Manolo.

⚠ La frecuencia acumulada no tiene sentido con variables nominales. Se puede calcular — matemáticamente nada lo impide— pero no significa nada. Sobre la tabla de familias de producto, la acumulada del 45,9 % + 33,0 % no permite decir que «el 78,9 % de las ventas son de familia inferior a accesorio». No hay orden.

Hay una salvedad importante: aunque la variable no tenga orden propio, se le puede imponer uno según **otro criterio**, típicamente la propia frecuencia. Ordenando descendentemente:

Familia	Absoluta	Relativa	Acum. relativa
Componente	1.240	45,9 %	45,9 %
Accesorio	890	33,0 %	78,9 %
Bicicleta	310	11,5 %	90,4 %
Ropa	260	9,6 %	100 %

Ahora sí tiene sentido: «dos familias concentran el 79 % de las operaciones». Es el fundamento del análisis de Pareto y de cualquier cálculo de cuota de mercado.

4.4. Agrupar en intervalos

Con una variable continua como el importe de venta, contar cuántas veces aparece cada valor exacto produce una tabla con miles de filas y frecuencia 1 en casi todas. No se ha resumido nada.

Importe	Frecuencia
34,90	1
35,00	2
35,15	1
35,20	1
...	...

La solución es agrupar en intervalos, que —como se vio en el capítulo 2— no es más que bajar la variable a una escala ordinal:

Importe (€)	Frecuencia	Relativa
0 – 25	620	23 %
26 – 75	980	36 %
76 – 200	640	24 %
201 – 800	340	13 %
más de 800	120	4 %
Total	2.700	100 %

La elección de los intervalos no es neutra: **cambiar los cortes cambia la historia** que cuenta el gráfico. Es una decisión de análisis, no un detalle técnico, y conviene documentarla.

4.5. Los gráficos asociados

- **Diagrama de barras.** Una barra por categoría, la altura es la frecuencia. El eje X no está graduado: las barras pueden ir en cualquier orden. Sirve para nominales, ordinales y cuantitativas discretas con pocos valores.
- **Diagrama de sectores.** Cada sector es una categoría y su tamaño es proporcional a la frecuencia relativa. El círculo entero es el 100 %. Sirve para mostrar **composición**, y sólo si hay pocas categorías.
- **Histograma.** Similar al de barras, pero el eje X está **graduado** porque la variable es continua. Cada barra ocupa su posición real y su anchura es la del intervalo. El área total es proporcional al número de individuos.
- **Polígono de frecuencias.** Une los puntos medios de las barras del histograma con una línea. Es una versión simplificada, útil para ver la forma de la distribución y para superponer dos grupos.

⚠ Barras y sectores no son intercambiables. La barra sirve para **comparar** magnitudes; el sector, para mostrar **partes de un todo**. El ojo humano compara longitudes con precisión y ángulos con muy poca, así que ante la duda, barras. Un diagrama de sectores con más de cinco categorías es prácticamente ilegible.

4.6. La moda

Es el indicador de tendencia central más sencillo: **el valor que más se repite**, el de mayor frecuencia.

En la tabla de familias, la moda es *componente*. En la de tiempos de reparación, el intervalo *0 – 4 horas*. En un diagrama de barras es la barra más alta; en uno de sectores, el sector mayor; en un histograma, el pico.

Se puede calcular para **cualquier escala de medida**, y es el único indicador de tendencia central disponible para variables nominales.

Precisiones:

- Puede no haber moda, si todos los valores aparecen una sola vez.
- Puede haber varias modas, si varios valores empatan.
- Aunque no haya empate exacto, si el histograma presenta varios picos se habla de distribución **multimodal**. Y eso es una señal importante: casi siempre indica que dentro del conjunto hay **dos poblaciones distintas mezcladas**. En Rueda Libre, el histograma de importe de venta tiene dos picos porque mezcla la venta de accesorios con la venta de bicicletas completas. La reacción correcta no es calcular indicadores sobre el conjunto: es separarlo.

4.7. La mediana

Es el valor que ocupa el **centro** del conjunto una vez ordenado de menor a mayor. Divide a los individuos en dos mitades del mismo tamaño.

Es la altura a la que se pondría el listón del limbo para que pasara justo la mitad de la gente.

Cálculo: se ordenan los datos. Si el número de valores es impar, la mediana es el central. Si es par, la media de los dos centrales.

5 7 8 11 14 19 40 → mediana = 11
5 7 8 11 14 19 40 55 → mediana = $(11+14)/2 = 12,5$

Sobre una tabla de frecuencias se localiza buscando el primer valor o intervalo cuya frecuencia acumulada relativa **alcanza o supera el 50 %**. En la tabla de tiempos de reparación, el primer intervalo que llega al 50 % es 5 – 8 horas: ahí está la mediana.

En un histograma, la mediana es el valor que divide el **área** en dos partes iguales.

Requiere poder ordenar, así que se puede calcular para variables ordinales y cuantitativas, pero **no para nominales**.

4.8. La media

Es el indicador más usado y el peor entendido. Se calcula sumando todos los valores y dividiendo entre el número de individuos.

Como requiere **sumar**, sólo se puede calcular sobre variables cuantitativas: las únicas que tiene sentido sumar. No se puede calcular la media de una variable cualitativa de ningún tipo, ordinal incluida.

La interpretación correcta, que casi nunca se enseña:

La media representa lo que aportaría cada individuo al total si todos aportaran exactamente lo mismo.

No dice que los individuos estén en torno a ese valor. Eso es lo que el cerebro humano asume automáticamente, y es la fuente de casi todos los errores de interpretación.

4.9. Cuándo la media engaña

El ejemplo canónico del curso. Dos pueblos de diez habitantes, midiendo los gramos de CO₂ que emiten al día sus vehículos.

Villa Arriba:

5 5 5 10 10 10 10 15 15 15
Media = 10 Mediana = 10

Villa Abajo. Nueve vecinos concienciados con un híbrido que emite 5. Y Manolo, con un tractor de mil caballos que emite 1.000:

5 5 5 5 5 5 5 5 5 1000

Media = 104,5 Mediana = 5

Mirando sólo la media, Villa Abajo parece diez veces más contaminante que Villa Arriba. Y es exactamente al revés: nueve de sus diez vecinos emiten la mitad que el vecino menos contaminante de Villa Arriba.

La media no miente —es cierto que si repartiéramos las emisiones a partes iguales tocarían a 104,5 por cabeza— pero **no resume bien al colectivo**, que era el objetivo. La mediana, 5, describe mucho mejor a esa población.

La versión de negocio del mismo fenómeno, que aparecerá en el cuadro de mando de Rueda Libre:

Tiempo de resolución de reparaciones

Media 3,2 días

Mediana 1,1 días

Percentil 90 8,7 días

Publicar sólo la media da una imagen falsa por arriba: la mayoría de los clientes recoge su bicicleta al día siguiente. Publicar sólo la mediana da una imagen falsa por abajo: uno de cada diez clientes espera más de ocho días, y éstos son los que escriben reseñas. **Los tres números juntos describen el servicio; ninguno lo hace por separado.**

4.10. Robusto y suficiente

La estadística tiene dos palabras para nombrar la diferencia:

- La **mediana** es un indicador **robusto**: no le afectan los valores extremos. Pero no es **suficiente**: para calcularla sólo se mira el centro, y se ignora el resto de la información.
- La **media** es **suficiente**: usa todos los valores del conjunto. Pero no es **robusta**: precisamente por usarlos todos, un solo valor extremo la desplaza.

La media aprovecha toda la información disponible, y por eso es sensible a los extremos. La mediana ignora casi toda la información, y por eso está protegida frente a ellos.

4.11. Cómo elegir

El criterio **no** es «si hay valores atípicos». El criterio es la **simetría de la distribución**, que se mira en el histograma o en el polígono de frecuencias.

- Si se puede trazar una línea vertical que deje dos mitades aproximadamente especulares, la distribución es **simétrica**: media y mediana serán parecidas y se puede usar la media.
- Si no, es **asimétrica**: media y mediana se separarán, y la mediana representará mejor al colectivo.

En la práctica se calculan las dos y se comparan. Si difieren mucho, hay asimetría. ¿Cuánto es «mucho»? Es un criterio subjetivo y depende del contexto: una diferencia de dos grados es irrelevante para decidir si se coge abrigo y enorme para estudiar el deshielo polar. Como orientación inicial, muchos analistas consideran que si la diferencia no supera el 10–15 % del valor de la mediana, las dos son suficientemente cercanas. No es una regla, es un punto de partida.

Y por encima de cualquier regla: **mirar el histograma primero**. La visualización resuelve en dos segundos lo que la comparación numérica sugiere en cinco minutos.

Ejercicios del capítulo 4

4.1. Con la tabla de tiempos de reparación del apartado 4.3, responde: ¿qué porcentaje de reparaciones tarda más de 24 horas? ¿Cuántas reparaciones tardan entre 5 y 24 horas? ¿En qué intervalo está la mediana?

4.2. El responsable de la tienda en línea afirma: «el 90,4 % de nuestras ventas son de familia igual o inferior a bicicleta». Explica qué está mal en la afirmación y qué habría que decir en su lugar.

4.3. El histograma del importe de venta de Rueda Libre tiene dos picos claros: uno hacia 40 € y otro hacia 900 €. ¿Qué está pasando? ¿Qué harías antes de calcular ningún indicador sobre esa variable?

4.4. Estos son los importes de las diez últimas ventas de una tienda: 38, 42, 45, 51, 55, 60, 68, 74, 90, 2.400. Calcula media y mediana. ¿Cuál publicarías en el cuadro de mando y por qué? ¿Qué harías con el valor de 2.400?

4.5. Rueda Libre presenta a la prensa el dato «ticket medio: 128 €». La mediana es 54 €. Redacta en dos frases cómo lo comunicarías tú para que sea igual de cierto y menos engañoso.

4.6. ¿Por qué no se puede calcular la media de la variable «prioridad de la reparación» (baja, normal, urgente) aunque se codifique como 1, 2 y 3? ¿Qué indicador de tendencia central usarías?

5. Dispersión, posición y forma

Este capítulo contiene la regla más importante del manual, y conviene enunciarla antes de explicar nada:

Nunca se ofrece un indicador de tendencia central sin su indicador de dispersión asociado.
Nunca. Ni en un informe, ni en un cuadro de mando, ni en una reunión.

5.1. Por qué una media sola no dice nada

Cuatro casas, cuatro habitantes cada una, midiendo su altura en centímetros:

Casa 1	160	165	175	180	Media 170	Mediana 170
Casa 2	160	160	180	180	Media 170	Mediana 170
Casa 3	170	170	170	170	Media 170	Mediana 170
Casa 4	155	170	170	185	Media 170	Mediana 170

Las cuatro casas son completamente distintas y los indicadores de tendencia central son idénticos. Con esos dos números no hay forma de distinguirlas.

La versión de negocio:

Empresa A	98	100	101	99	102	Media 100
Empresa B	20	50	100	150	180	Media 100

Misma media, realidad empresarial opuesta. La A es predecible y se puede planificar; la B no. Cualquier decisión —dimensionar un almacén, fijar un objetivo, contratar personal— sería distinta en cada caso.

Hace falta un segundo número que mida **cuánto se alejan los datos de la tendencia central**.

5.2. El camino hasta la desviación típica

Merece la pena recorrerlo, porque explica por qué la fórmula es como es.

Primer intento: la diferencia respecto a la media. Se llama *puntuación diferencial*.

Casa 1	-10	-5	5	10
Casa 2	-10	-10	10	10
Casa 3	0	0	0	0
Casa 4	-15	0	0	15

Segundo intento: promediar esas diferencias. Y aquí llega el chasco: da cero en las cuatro casas. Los valores por encima de la media anulan exactamente a los que están por debajo. Siempre. Por construcción.

Lo que interesa no es si se desvían por arriba o por abajo, sino **cuánto** se desvían. Hay que eliminar el signo, y en matemáticas hay dos operaciones habituales para ello.

Tercer intento: el valor absoluto. Promediando los valores absolutos de las diferencias se obtiene la **desviación media**:

Casa 1	$(10+5+5+10)/4 = 7,5$
Casa 2	$(10+10+10+10)/4 = 10$
Casa 3	0
Casa 4	$(15+0+0+15)/4 = 7,5$

Mejor, pero insuficiente: las casas 1 y 4 obtienen el mismo valor teniendo distribuciones claramente distintas. Por eso hoy apenas se usa.

Cuarto intento: el cuadrado. Promediando los cuadrados de las diferencias se obtiene la **varianza**:

Casa 1	$(100+25+25+100)/4 = 62,5$
Casa 2	$(100+100+100+100)/4 = 100$
Casa 3	0
Casa 4	$(225+0+0+225)/4 = 112,5$

Ahora sí se distinguen las cuatro. Elevar al cuadrado penaliza más las desviaciones grandes que las pequeñas, que es justo lo que se quería.

El problema de la varianza es su interpretación: al elevar al cuadrado, **las unidades también se elevan al cuadrado**. La varianza de la casa 1 es 62,5 cm². Una superficie, midiendo alturas. Y con importes es peor: ¿alguien ha visto alguna vez un euro cuadrado?

Quinto y definitivo: la raíz cuadrada de la varianza, que devuelve el resultado a las unidades originales. Es la **desviación típica** o **desviación estándar**:

Casa 1	$\sqrt{62,5} = 7,9 \text{ cm}$
Casa 2	$\sqrt{100} = 10 \text{ cm}$
Casa 3	$\sqrt{0} = 0 \text{ cm}$
Casa 4	$\sqrt{112,5} = 10,6 \text{ cm}$

Ahora el número está en centímetros y se puede interpretar.

5.3. Cómo se interpreta la desviación típica

La desviación típica indica cuánto se alejan los datos de la media en términos generales. Cuanto mayor, más dispersos; cuanto menor, más concentrados.

Para convertir eso en una afirmación concreta hay dos herramientas, y conviene no confundirlas porque la confusión está muy extendida.

La desigualdad de Chebyshev dice que, sea cual sea la distribución, la proporción de individuos que caen a menos de k desviaciones típicas de la media es al menos $1 - 1/k^2$:

k	Intervalo	Contiene al menos
1	media $\pm 1\sigma$	— (la desigualdad no dice nada)
1,41	media $\pm 1,41\sigma$	50 %
2	media $\pm 2\sigma$	75 %
3	media $\pm 3\sigma$	89 %

La regla empírica dice que si la distribución es **aproximadamente normal** —una campana simétrica— entonces:

Intervalo	Contiene aproximadamente
media $\pm 1\sigma$	68 %
media $\pm 2\sigma$	95 %
media $\pm 3\sigma$	99,7 %

⚠ Es muy frecuente oír que «media ± 1 desviación típica contiene al menos el 50 % de los casos, sea cual sea la distribución». **Es falso.** Chebyshev para $k = 1$ no garantiza nada, y el 68 % de la regla empírica exige normalidad. La casa 2 del ejemplo (160, 160, 180, 180) tiene media 170 y $\sigma = 10$: el intervalo [160, 180] contiene el 100 % de los individuos, no el 50 %. La afirmación segura, la que siempre se cumple, es la de **$\pm 2\sigma$ y el 75 %**.

Aplicado a Rueda Libre: si el ticket medio de una tienda es de 128 € con una desviación típica de 45 €, se puede afirmar sin conocer la distribución que **al menos tres de cada cuatro tickets están entre 38 € y 218 €**. Es una frase que un comité de dirección entiende, y es cierta.

5.4. El rango

El indicador de dispersión más simple: máximo menos mínimo.

Casa 1: $180 - 160 = 20$ cm

Casa 4: $185 - 155 = 30$ cm

Es muy fácil de calcular y muy poco fiable, porque depende exclusivamente de los dos valores más extremos: exactamente los más propensos a ser errores. Sirve como comprobación rápida de plausibilidad —si el rango de un importe de venta va de -300 € a $2.000.000$ €, hay un problema de calidad— y poco más.

5.5. Las medidas de posición

La mediana, vista en el capítulo anterior, es en realidad una medida de posición: el valor que deja por debajo al 50 %. Generalizando la idea:

- **Cuartiles.** Dividen el conjunto en cuatro partes iguales.
- **Q1:** deja por debajo al 25 %.
- **Q2:** deja por debajo al 50 %. **Es la mediana.**
- **Q3:** deja por debajo al 75 %.
- **Deciles.** Diez partes. D1 deja por debajo al 10 %, D9 al 90 %.
- **Percentiles.** Cien partes. $P_{25} = Q_1$, $P_{50} =$ mediana, P_{90} , P_{95} , P_{99} .

Todos coinciden en los puntos comunes: $D_5 = P_{50} = Q_2 =$ mediana.

Se localizan en una tabla de frecuencias mirando la columna de frecuencia acumulada relativa: el cuartil Q1 es el primer intervalo que alcanza el 25 %, Q3 el primero que alcanza el 75 %.

Por qué le importan al negocio. Los percentiles altos son el lenguaje natural de los compromisos de servicio y del dimensionamiento:

P_{90} del tiempo de reparación = 8,7 días

→ «9 de cada 10 clientes recogen su bicicleta antes de 9 días»

→ Es el número que se puede comprometer en el acuerdo de servicio

P_{95} de la concurrencia en la web = 340 usuarios simultáneos

→ Es el número con el que se dimensiona el servidor, no la media

La media sirve para entender el conjunto. Los percentiles sirven para comprometerse con alguien. Ningún cliente vive en la media.

5.6. El rango intercuartílico

Cuando la distribución es asimétrica y se usa la mediana como tendencia central, la desviación típica — que se calcula a partir de la media— deja de ser el compañero adecuado. El indicador de dispersión asociado a la mediana es el **rango intercuartílico** (IQR):

$$\text{IQR} = Q3 - Q1$$

Como Q1 deja por debajo al 25 % y Q3 al 75 %, el IQR mide la amplitud del intervalo que contiene al **50 % central** de los individuos: los más representativos del colectivo, los que están alrededor de la mediana.

Ese 50 % es el mismo 50 % del que hablaba Chebyshev con $\pm 1,41\sigma$, y por eso ambos indicadores tienen una interpretación equivalente:

Tendencia central	Dispersión	Interpretación
Media	Desviación típica (σ)	media $\pm 2\sigma$ contiene al menos el 75 %
Mediana	Rango intercuartílico	Q1 a Q3 contiene el 50 % central

En Rueda Libre, con reparaciones de mediana 1,1 días, Q1 = 0,6 y Q3 = 3,4:

$$\text{IQR} = 3,4 - 0,6 = 2,8 \text{ días}$$

→ «La mitad de las reparaciones se resuelven entre medio día y tres días y medio»

5.7. Simetría y asimetría

La **forma** de la distribución es lo que determina qué indicadores usar. Se mira en el histograma o en el polígono de frecuencias.

Simétrica. Se puede trazar un eje vertical que deje dos mitades especulares. Media, mediana y moda coinciden aproximadamente. Se puede usar la media.

Asimétrica positiva (cola hacia la derecha). La mayoría de los valores están en la parte baja y unos pocos muy altos estiran la cola. Es la forma más frecuente en negocio: importes de venta, salarios, tiempos de espera, valor de cliente.

$$\text{media} > \text{mediana} > \text{moda}$$

En Rueda Libre, el importe de venta: muchísimas ventas de 30 €, unas pocas bicicletas de 3.000 €. La media está inflada por esas pocas; la mediana describe mejor a la clientela habitual.

Asimétrica negativa (cola hacia la izquierda). La mayoría de los valores están en la parte alta y unos pocos muy bajos estiran la cola. Menos frecuente. El ejemplo clásico es la edad de jubilación: casi todo el mundo se jubila alrededor de los 65 y unos pocos mucho antes.

media < mediana < moda

Regla práctica: si la media es claramente mayor que la mediana, hay asimetría positiva y unos pocos valores altos están tirando de ella. Si es claramente menor, asimetría negativa. Si son parecidas, la distribución es aproximadamente simétrica.

Y una imagen que ayuda a recordarlo: la media siempre quiere estar junto a la mediana, pero los valores extremos tiran de ella. Manolo, con su tractor, arrastra la media hacia arriba. Gertru, que consume CO₂ en lugar de producirlo, tira hacia abajo y la devuelve a su sitio.

5.8. Valores atípicos

Un **valor atípico** es una observación que se aleja mucho del resto. El criterio más extendido para detectarlos usa el rango intercuartílico:

Límite inferior razonable = $Q1 - 1,5 \times IQR$

Límite superior razonable = $Q3 + 1,5 \times IQR$

Fuera de esos límites → valor atípico

Más allá de $Q1/Q3 \pm 3 \times IQR$ → valor atípico extremo

El factor 1,5 es una convención, no una ley: en algunos contextos se usa 2 o más, según la naturaleza de los datos.

Y ahora la pregunta que de verdad importa, y que no responde ninguna fórmula:

¿Este valor atípico es un **error de dato** o es la **realidad**?

Son dos situaciones opuestas y la reacción es opuesta:


Es un error	Es real
Importe de 1.250.000 € por céntimos mal convertidos	Una venta corporativa de 40 bicicletas
Reparación de -3 días por fechas invertidas	La restauración completa de Manolo, 21 días
Cliente con 400 años por fecha 01/01/1900	El cliente que compra doce veces al año
Se corrige o se elimina	Se conserva, y a menudo se estudia aparte

⚠ Eliminar valores atípicos porque «ensucian el gráfico» es una de las peores prácticas del análisis de datos. Con frecuencia el atípico es lo más interesante del conjunto: el fraude, el cliente más rentable, el fallo de proceso, la oportunidad de negocio. En detección de fraude y en mantenimiento predictivo, el atípico **es** el objeto de estudio.

Manolo, con sus restauraciones de tres semanas, es un valor atípico en el tiempo de reparación. No es un error: es una línea de negocio distinta, con márgenes distintos y clientes distintos. La decisión correcta no es borrarlo del conjunto, es **segmentar**: analizar por separado la reparación estándar y la restauración.

5.9. El diagrama de caja y bigotes

Con la mediana, los cuartiles, el rango intercuartílico y los atípicos ya se puede leer uno de los gráficos más compactos de la estadística.



Cómo se lee, en este orden:

1. **La caja** va de Q1 a Q3: contiene el 50 % central de los datos. Su anchura es el IQR, es decir, la dispersión.
2. **La línea interior** es la mediana. Si no está centrada en la caja, hay asimetría.
3. **Los bigotes** llegan hasta el último dato que cae dentro de $1,5 \times \text{IQR}$. Son el mínimo y el máximo *razonables*, no el mínimo y el máximo reales.
4. **Los puntos sueltos** son los valores atípicos, cada uno individualmente.
5. Si la caja entera está desplazada a un lado, la distribución es asimétrica.
6. A veces se marca también la media con una X. Si la X y la mediana están separadas, hay asimetría.

Es la navaja suiza del análisis de datos cuantitativos: en un dibujo minimalista muestra dónde está el centro, cuánta dispersión hay, si la distribución es simétrica y si hay Manolos sueltos.

Su mayor virtud aparece al **comparar grupos**: doce cajas, una por tienda, en el mismo eje, permiten ver en un segundo qué tienda tiene el ticket más alto, cuál el más irregular y cuál acumula operaciones anómalas.

5.10. El gráfico de violín

Es un diagrama de caja al que se le añade, a ambos lados, la forma de la distribución —un histograma suavizado—, lo que le da su silueta característica.

Aporta lo único que el boxplot no puede mostrar: **si la distribución es multimodal**. Dos distribuciones con idénticos cuartiles pueden tener una sola concentración central o dos grupos separados, y el boxplot las dibuja igual. El violín las distingue de un vistazo.

Ejercicios del capítulo 5

5.1. La tienda de Valencia tiene un ticket medio de 128 € con desviación típica de 45 €. La de Zaragoza, 128 € con desviación típica de 12 €. Describe en dos frases en qué se diferencian los dos negocios y qué decisión distinta tomarías en cada uno.

5.2. Usando Chebyshev, escribe la afirmación más fuerte que puedas hacer sobre el ticket de Valencia sin conocer su distribución. Después escribe la que podrías hacer si supieras que es aproximadamente normal. ¿Cuál publicarías?

5.3. Reparaciones de una tienda, en días: 0,5 · 0,5 · 1 · 1 · 1 · 1,5 · 2 · 2 · 3 · 4 · 5 · 21
Calcula mediana, Q1, Q3 e IQR. Aplica el criterio de $1,5 \times \text{IQR}$: ¿cuáles son atípicos? ¿Qué harías con ellos?

5.4. Un analista propone eliminar del conjunto todas las reparaciones de más de 10 días «porque distorsionan el indicador». Argumenta a favor y en contra, y decide.

5.5. Dibuja aproximadamente el histograma del importe de venta de Rueda Libre sabiendo que media = 128 €, mediana = 54 € y moda = 35 €. ¿Cómo se llama esa forma? ¿Qué indicador de tendencia central publicarías?

5.6. Explica por qué dos distribuciones pueden tener exactamente el mismo diagrama de caja y bigotes y ser muy distintas. ¿Qué gráfico usarías para distinguirlas?

5.7. El comité de dirección pide «un solo número» para el tiempo de reparación. Explica por qué te niegas y qué propones en su lugar, en tres cifras como máximo.

6. Sistemas operacionales y sistemas analíticos

Hasta aquí se ha hablado de qué hacer con los datos. Este capítulo trata de dónde salen y por qué hace falta moverlos de sitio antes de analizarlos.

6.1. Sistemas OLTP

OLTP son las siglas de *On-Line Transaction Processing*: procesamiento de transacciones en línea. Son los sistemas que sostienen la operación diaria: el TPV de la tienda, el gestor del taller, la tienda en línea, el ERP.

Están diseñados con un objetivo muy concreto: **registrar muchas operaciones pequeñas, muy deprisa y sin perder ninguna**. Todo en ellos está optimizado para eso.

La consecuencia de diseño más visible es la **normalización**: los datos se reparten en muchas tablas pequeñas sin repetir información. El nombre de un cliente está en un sitio y sólo en uno; las líneas de ticket guardan un identificador que apunta a él.

```
CLIENTES      (id, nombre, email, teléfono, id_población)
POBLACIONES   (id, nombre, cp, id_provincia)
PROVINCIAS    (id, nombre, id_comunidad)
TICKETS       (id, fecha, id_cliente, id_tienda, id_forma_pago)
LINEAS_TICKET (id, id_ticket, id_articulo, unidades, precio, descuento)
ARTICULOS     (id, descripción, id_familia, id_marca, id_proveedor)
FAMILIAS      (id, nombre, id_seccion)
...
```

La normalización es excelente para operar: si un cliente cambia de teléfono se modifica un único registro, y no hay forma de que queden dos versiones distintas. Es pésima para analizar: responder «ventas por familia de producto y provincia en el último trimestre» exige cruzar seis o siete tablas y recorrer millones de líneas.

⚠ Lanzar consultas analíticas contra la base de datos de producción es una mala idea por dos motivos independientes. El primero es de rendimiento: una consulta que recorre tres años de ventas bloquea recursos y ralentiza el cobro en caja. El segundo es más sutil: el sistema operativo **guarda el estado actual, no el histórico**. Si un artículo cambia de familia, todas las ventas pasadas empiezan a contabilizarse en la familia nueva, y el informe del año pasado deja de coincidir con el que se emitió el año pasado.

6.2. OLTP frente a OLAP

OLAP es *On-Line Analytical Processing*. Es la contrapartida: sistemas diseñados para responder pocas preguntas muy grandes.

	OLTP	OLAP
Propósito	Operar	Analizar y decidir
Operación típica	Insertar y actualizar registros	Leer y agregar millones de filas
Diseño	Normalizado, muchas tablas	Desnormalizado, modelo dimensional
Granularidad	El registro individual	Agregados y detalle histórico
Horizonte temporal	El estado actual	Años de historia
Volumen por consulta	Unas pocas filas	Millones de filas
Frecuencia de escritura	Continua	Por lotes, típicamente nocturna
Concurrencia	Cientos o miles de usuarios	Decenas de analistas
Criterio de éxito	Milisegundos por transacción	Segundos por consulta compleja
Si se cae	Se para el negocio	No se puede decidir, pero se opera

Son dos oficios distintos que exigen dos diseños distintos. Intentar que un solo sistema haga los dos bien es la razón por la que muchas organizaciones tienen una base de datos lenta para operar e insuficiente para analizar.

6.3. El almacén de datos

Un **Data Warehouse** o almacén de datos es un repositorio único donde se integra la información procedente de todas las fuentes, preparada para el análisis.

La definición clásica de Bill Inmon lo caracteriza con cuatro propiedades:

Integrado. Los datos de todas las fuentes se unifican bajo criterios comunes: mismos códigos, mismas unidades, mismos nombres. Es lo que resuelve el problema de las cuatro definiciones de «venta» de Rueda Libre.

Temático (orientado a materias). Se organiza por áreas de negocio —ventas, clientes, taller, stock— y no por la aplicación de la que procede el dato. A quien analiza le da igual si la venta vino del TPV o de la web.

No volátil. Los datos no se modifican ni se borran. Se cargan y se conservan. Un informe emitido hace dos años debe poder reproducirse hoy con el mismo resultado.

Histórico (variante en el tiempo). Guarda la evolución, no sólo el estado actual. Y guarda cómo eran las cosas *cuando ocurrieron*: si una tienda cambió de región comercial en 2024, las ventas de 2023 siguen perteneciendo a la región antigua.

Ventajas concretas:

- Una versión única de la verdad. Todos los informes parten del mismo dato.
- Rendimiento analítico, sin afectar a los sistemas de operación.
- Historia completa, incluso de fuentes que ya no existen.
- Reglas de negocio aplicadas una sola vez y en un solo sitio.
- Trazabilidad: se puede saber de dónde salió cada cifra.

Y su coste, que también conviene decir:

- Los datos no están al minuto: se cargan por lotes.
- Cualquier cambio en una fuente obliga a tocar el proceso de carga.
- Requiere mantenimiento continuo y alguien responsable.
- El esfuerzo inicial es alto y el retorno tarda meses en verse.

6.4. Datamarts

Un **datamart** es un subconjunto del almacén orientado a un área concreta: ventas, taller, compras. Contiene sólo lo que ese departamento necesita, con el nivel de detalle que ese departamento usa.

Se justifica por tres razones: rendimiento, simplicidad para el usuario final, y control de acceso. Un responsable de tienda no necesita —ni debe— ver los costes de proveedor.

Hay dos formas de llegar a ellos, que históricamente dieron lugar a un debate considerable:

Enfoque descendente (Inmon). Primero se construye el almacén corporativo completo y normalizado, y de él se derivan los datamarts. Más coherente y más lento de rentabilizar.

Enfoque ascendente (Kimball). Se construyen primero los datamarts de las áreas más urgentes, garantizando que comparten **dimensiones conformadas** —el mismo cliente, el mismo producto, el mismo calendario—, y el almacén emerge de su unión. Da resultados antes y exige más disciplina.

En la práctica casi todos los proyectos actuales son ascendentes por necesidad: nadie financia dos años de construcción sin ver un cuadro de mando. Lo que no es negociable, sea cual sea el enfoque, es que las dimensiones estén conformadas. Un datamart de ventas y otro de taller que definan «cliente» de forma distinta son dos silos, no un almacén.

6.5. Las capas del almacén

La arquitectura moderna organiza el almacén en capas sucesivas de refinado. Los nombres varían; la idea es siempre la misma:

FUENTES	TPV · web · taller · ERP · clientes · objetivos.xlsx
↓	
STAGING	Copia en bruto, tal cual llegó. Sin transformar.
↓	Sirve para reprocesar sin volver a molestar a la fuente.
INTEGRACIÓN	Datos limpios, deduplicados, conformados, historificados.
↓	Aquí está la versión única de la verdad.
PRESENTACIÓN	Modelo dimensional: hechos y dimensiones, listo para consultar.
↓	
CONSUMO	Cuadros de mando, informes, análisis, modelos

La capa de *staging* parece redundante y no lo es: permite reprocesar toda la historia si se descubre un error en las reglas de transformación, sin depender de que los sistemas de origen conserven el dato.

6.6. Historificación y dimensiones lentamente cambiantes

Un atributo descriptivo puede cambiar con el tiempo. Una tienda cambia de responsable, un cliente cambia de segmento, un artículo cambia de familia. ¿Qué debe pasar con la historia?

Las tres estrategias clásicas, conocidas como *Slowly Changing Dimensions*:

Tipo 1 · Sobrescribir. Se actualiza el valor y se pierde el anterior. Toda la historia pasa a verse con el valor nuevo. Correcto para corregir errores —una provincia mal escrita— e incorrecto para cambios reales.

Tipo 2 · Versionar. Se crea un registro nuevo con fechas de validez y se cierra el anterior. Cada venta queda asociada a la versión que estaba vigente cuando ocurrió.

id_tienda	nombre	región	desde	hasta	vigente
17	Valencia	Levante	2019-01-01	2024-06-30	No
17	Valencia	Este	2024-07-01	9999-12-31	Sí

Las ventas de 2023 siguen perteneciendo a Levante. Es lo correcto para la mayoría de los cambios de negocio, y lo que hace que un informe antiguo se pueda reproducir.

Tipo 3 · Conservar el valor anterior en otra columna. Permite comparar el antes y el después, pero sólo guarda un cambio. De uso poco frecuente.

⚠ La decisión sobre qué atributos se historifican y cuáles no es una decisión de **negocio**, no técnica. Debe tomarla quien va a leer los informes, porque es quien sabe si «las ventas de la región Este» deben

incluir o no las que Valencia hizo cuando pertenecía a Levante. Cambiarla más adelante obliga a reconstruir el histórico.

Ejercicios del capítulo 6

- 6.1.** Rueda Libre reorganiza sus regiones comerciales en julio. El director comercial quiere comparar la venta de la región Este de este año con la del año pasado. ¿Qué tipo de dimensión lentamente cambiante necesita? ¿Y si lo que quisiera es analizar la evolución con la estructura actual?
- 6.2.** Un consultor propone conectar el cuadro de mando directamente al TPV «para tener el dato en tiempo real y ahorrarse el almacén». Enumera cuatro problemas concretos que aparecerían, al menos uno que no sea de rendimiento.
- 6.3.** Explica con el ejemplo de Rueda Libre qué significa cada una de las cuatro propiedades de Inmon. Usa un caso distinto para cada una.
- 6.4.** El departamento de taller quiere su propio datamart y propone definir «cliente» como quien trae la bicicleta, mientras que ventas lo define como quien paga. ¿Qué problema causará y cómo lo resolverías?
- 6.5.** ¿Para qué sirve la capa de *staging* si los datos luego se transforman de todas formas? Da un caso concreto en el que salve un proyecto.
-

7. Procesos ETL

ETL son las tres operaciones que llevan el dato desde los sistemas de origen hasta el almacén:

Extracción, Transformación y Carga. Es la parte menos vistosa de un proyecto de BI y la que consume la mayor parte del presupuesto.

7.1. Extracción

Consiste en obtener los datos de cada fuente. Las decisiones importantes:

Qué se extrae cada vez.

- *Carga completa*: se trae todo el conjunto en cada ejecución. Simple y robusto, inviable con volúmenes grandes.
- *Carga incremental*: sólo lo que ha cambiado desde la última ejecución. Eficiente y frágil: exige un criterio fiable de «lo que ha cambiado», normalmente una marca de tiempo de modificación. Si la fuente no la mantiene bien, se pierden registros silenciosamente.
- *Captura de cambios* (CDC): se leen los cambios directamente del registro de transacciones de la base de datos de origen. Es lo más preciso y lo más intrusivo.

Cuándo se extrae. La ventana de extracción suele ser nocturna, para no competir con la operación. Eso fija la latencia del almacén: si la carga es a las tres de la mañana, el cuadro de mando muestra los datos de ayer. Es una decisión de negocio disfrazada de decisión técnica, y hay que hacerla explícita.

Cómo se trata el fallo. Toda extracción falla alguna vez: la fuente no responde, el fichero no está, el formato cambió. El proceso debe poder repetirse sin duplicar datos —lo que se llama ser *idempotente*— y debe avisar.

⚠ El fallo más caro no es el que rompe el proceso: es el que lo deja terminar con datos incompletos. Un cuadro de mando que muestra media jornada de ventas sin advertirlo provoca decisiones erróneas con total confianza. Toda carga debe validar volúmenes esperados y marcar el resultado como completo o parcial.

7.2. Transformación

Es la fase larga. Agrupa todo lo que hay que hacerle al dato para que sea analizable. En el caso de Rueda Libre:

Limpieza. Corregir o marcar lo que está mal: fechas imposibles, importes negativos donde no puede haberlos, campos obligatorios vacíos.

Normalización de formatos. Todo a un mismo criterio: fechas en formato único, textos sin espacios sobrantes, mayúsculas y minúsculas homogéneas, teléfonos sin separadores.

Conversión de unidades. Céntimos a euros, minutos a horas, divisas a euros con el cambio de la fecha de la operación —no con el de hoy.

Deduplicación. Aplicar la regla de identidad y unificar los tres Manolos en uno, conservando la trazabilidad de qué registros originales se fusionaron.

Conformado de dimensiones. Traducir los códigos de cada fuente a un catálogo común:

```
TPV "BICICLETA"  1
Web "Bici"       |→ familia = BIC · «Bicicletas»
ERP "BIC"        J
```

Este paso es el que hace que el almacén sea un almacén y no un montón de tablas juntas.

Aplicación de reglas de negocio. Aquí se decide, de una vez y para toda la organización, qué significa cada concepto:

```
¿Una venta es el pedido o el cobro?
¿Las devoluciones restan de la venta del mes original o del mes de la devolución?
¿El descuento va antes o después de impuestos?
¿Un traspaso entre tiendas es una venta?
```

Estas decisiones no las toma quien programa el proceso de carga. Las toma el negocio, y quedan documentadas. Es la única forma de que dos informes no den dos cifras distintas de la misma cosa.

Cálculo de derivados. Márgenes, duraciones, edades, indicadores intermedios. Se calculan una vez en la carga en lugar de en cada consulta.

Enriquecimiento. Añadir información externa: población del municipio, datos meteorológicos por fecha y tienda —muy relevante en un negocio de bicicletas—, calendario de festivales.

7.3. Carga

Escribir el resultado en el almacén. Los puntos a decidir:

- **Orden.** Primero las dimensiones, después los hechos. Un hecho que apunta a una dimensión inexistente queda huérfano.
- **Gestión de la historia.** Aplicar la estrategia de dimensión lentamente cambiante que corresponda a cada atributo.
- **Huérfanos.** ¿Qué hacer con una venta cuyo artículo no está en el catálogo? La práctica habitual es asignarla a un miembro «desconocido» de la dimensión, nunca descartarla: si se descarta, los

totales dejan de cuadrar y nadie sabe por qué.

- **Transaccionalidad.** O se carga todo el lote o no se carga nada. Un almacén con media carga aplicada es peor que uno con los datos de ayer.

7.4. ETL frente a ELT

El orden clásico es extraer, transformar y luego cargar: la transformación ocurre en un servidor intermedio antes de escribir en el almacén.

En los últimos años se ha impuesto el orden **ELT**: extraer, cargar en bruto y transformar **dentro** del propio almacén.

El motivo es económico y técnico: los almacenes actuales —columnares, distribuidos, en la nube— tienen mucha más capacidad de cálculo que cualquier servidor intermedio, y se paga por uso. Cargar primero y transformar después permite además reprocesar toda la historia sin volver a las fuentes.

	ETL	ELT
Dónde se transforma	Servidor intermedio	Dentro del almacén
Qué se carga	Sólo el dato ya limpio	Todo, también el bruto
Reprocesar	Hay que volver a la fuente	Se rehace en el almacén
Coste de almacenamiento	Menor	Mayor
Encaja con	Volúmenes moderados, infraestructura propia	Nube, grandes volúmenes

⚠ El cambio de ETL a ELT es un cambio de **dónde** se ejecuta la transformación, no de **si** hace falta transformar. La idea de que con un *data lake* ya no hace falta limpiar los datos es la causa directa de muchos proyectos que terminan en lo que el sector llama, sin cariño, un *data swamp*: un depósito de ficheros que nadie sabe interpretar.

7.5. Orquestación

Los procesos de carga tienen dependencias: el hecho de ventas no puede cargarse antes que la dimensión de producto. Un orquestador define ese grafo, ejecuta cada paso cuando le toca, reintenta lo que falla y avisa.

Lo que hay que dejar resuelto antes de la primera ejecución en producción:

- Qué pasa si una fuente no responde: ¿se para todo o se carga el resto?
- Cuánto tiempo puede tardar como máximo antes de considerarse un fallo.
- A quién se avisa, por qué canal y con qué información.
- Cómo se relanza una carga concreta sin rehacerlo todo.

- Cómo sabe quien lee el cuadro de mando que el dato de hoy es incompleto.

7.6. Gobierno del dato

El proceso técnico no basta. Hace falta una estructura de responsabilidad:

Propietario del dato. Una persona concreta, del negocio, responsable de cada conjunto: quién decide qué es un cliente activo, quién autoriza cambios en el catálogo de familias. Sin propietario, las decisiones las acaba tomando por defecto quien programa la carga, que es quien menos contexto tiene.

Diccionario de datos. Para cada campo: qué significa, de dónde sale, cómo se calcula, con qué frecuencia se actualiza, quién responde de él.

Linaje. La trazabilidad de cada cifra hasta su origen. Cuando alguien pregunta «¿de dónde sale este 142.000?», debe haber respuesta.

Definición única de KPI. El catálogo de indicadores, con su fórmula exacta y su propietario. Es lo que evita que comercial y finanzas lleven dos cifras de venta a la misma reunión.

Si en una reunión dos departamentos discuten sobre qué cifra es la buena, el problema no es de datos: es de gobierno. Y no lo arregla ninguna herramienta.

Ejercicios del capítulo 7

7.1. El TPV de Bilbao estuvo tres días sin conexión y volcó sus ventas de golpe el cuarto. ¿Qué habría pasado con una carga incremental basada en fecha de modificación? ¿Y con una carga completa? ¿Qué control lo habría detectado?

7.2. Escribe la regla de negocio para las devoluciones en Rueda Libre. Considera las dos opciones posibles, di cuál eliges, y explica qué informe cambia según la elección.

7.3. Una venta llega con un código de artículo que no existe en el catálogo. Enumera tres formas de tratarlo en la carga y las consecuencias de cada una en el cuadro de mando.

7.4. Diseña el orden de carga de las tablas de Rueda Libre —cliente, tienda, producto, fecha, ventas, reparaciones— y justifica las dependencias.

7.5. La dirección quiere el cuadro de mando «en tiempo real». La carga es nocturna. Enumera tres preguntas que le harías antes de aceptar o rechazar el requisito.

8. El modelo dimensional

El modelo es la decisión más duradera de un proyecto de BI. Determina qué preguntas se van a poder hacer y, sobre todo, cuáles no.

8.1. Hechos y dimensiones

El modelo dimensional organiza los datos en dos tipos de tabla.

Las tablas de hechos guardan lo que ocurre: eventos medibles. Contienen **métricas** —valores cuantitativos— y las claves que apuntan a las dimensiones. Son las tablas grandes: millones de filas.

Las tablas de dimensión guardan el contexto: quién, qué, dónde, cuándo, cómo. Contienen **atributos** descriptivos, casi siempre textos. Son tablas pequeñas y anchas.

Y aquí está la conexión con el capítulo 2, que conviene subrayar:

Las dimensiones son las variables medidas en escala **nominal y ordinal**. Los hechos son las variables medidas en escala **cuantitativa**.

Quien sepa determinar la escala de medida de cada columna tiene el modelo medio diseñado. Un código postal es texto disfrazado de número: dimensión. Un importe tiene unidad: hecho.

En Rueda Libre:

HECHO_VENTAS		DIMENSIONES	
id_fecha	→ DIM_FECHA	fecha, mes, trimestre, año, festivo, temporada	
id_tienda	→ DIM_TIENDA	nombre, ciudad, provincia, región, m², apertura	
id_producto	→ DIM_PRODUCTO	descripción, familia, marca, gama	
id_cliente	→ DIM_CLIENTE	segmento, antigüedad, canal de captación	
id_forma_pago	→ DIM_PAGO	tipo, plazo	
unidades		← métricas	
importe_bruto			
descuento			
importe_netto			
coste			
margen			

8.2. La granularidad

Es **la decisión más importante del proyecto**, y hay que tomarla antes que ninguna otra. La granularidad, o grano, es lo que representa una fila de la tabla de hechos.

La prueba consiste en completar esta frase sin ambigüedad:

«Una fila de HECHO_VENTAS es ...»

Opciones para Rueda Libre, de más fino a más grueso:

... una línea de ticket ← máximo detalle
... un ticket completo
... las ventas de un producto en una tienda y un día
... las ventas de una tienda y un día
... las ventas de una tienda y un mes ← mínimo detalle

La regla es clara y se deduce directamente de la escalera de medida del capítulo 2: **se elige siempre el grano más fino que sea viable**. Desde el detalle se puede agregar en cualquier momento; desde el agregado no se puede desagregar nunca.

⚠ Un almacén cargado al grano de «tienda y mes» no podrá responder jamás a «¿qué productos se venden juntos?» ni a «¿a qué hora vendemos más?». No es un problema que se arregle con una consulta: el dato ya no está. Y volver atrás significa recargar toda la historia, si las fuentes todavía la conservan.


También hay que decidir el grano de las reparaciones, que es distinto:

«Una fila de HECHO_REPARACIONES es una orden de reparación cerrada»

Y ahí ya aparece una decisión de negocio: ¿y las que siguen abiertas? Si sólo se cargan las cerradas, el tiempo medio de reparación estará sistemáticamente subestimado, porque las que más tardan son precisamente las que aún no han cerrado. Es un sesgo real, tiene nombre —sesgo de supervivencia— y se resuelve cargando también las abiertas con su estado.

8.3. Estrella y copo de nieve

Esquema en estrella. Una tabla de hechos en el centro y las dimensiones alrededor, cada una en una sola tabla, desnormalizada: la dimensión de tienda contiene ciudad, provincia y región en columnas, aunque eso repita «Valencia» miles de veces.



Esquema en copo de nieve. Las dimensiones se normalizan en varias tablas enlazadas: tienda → ciudad → provincia → región.

La estrella ahorra cruces y es mucho más comprensible para quien construye informes. El copo ahorra espacio y evita algunas inconsistencias. En la práctica **se prefiere la estrella** casi siempre: el espacio es barato y la comprensión del modelo por parte del usuario final es lo que determina si el almacén se usa o se abandona.

8.4. Jerarquías

Dentro de una dimensión, los atributos se organizan en niveles de detalle. Son las jerarquías, y son las que hacen posible la navegación del análisis:

Geografía	Región → Provincia → Ciudad → Tienda
Producto	Sección → Familia → Marca → Artículo
Tiempo	Año → Trimestre → Mes → Semana → Día
Empresa	Dirección → Región comercial → Tienda → Empleado

Una dimensión puede tener varias jerarquías alternativas. El tiempo, por ejemplo, tiene la natural (año–trimestre–mes–día) y la semanal (año–semana–día), que no encajan una en otra: una semana puede pertenecer a dos meses.

8.5. La dimensión Fecha

Merece apartado propio porque está en todos los modelos y siempre se construye a mano. Nunca se deriva de la fecha de la transacción sobre la marcha: se genera una tabla con una fila por día, cubriendo todo el horizonte del almacén.

fecha	año	trim	mes	nombre_mes	semana	día_sem	laborable	festivo	temporada
2026-04-03	2026	2	4	Abril	14	Viernes	Sí	No	Alta

Lo que aporta es la posibilidad de responder preguntas que la fecha por sí sola no permite: comparar el mismo día de la semana entre meses, excluir festivos, medir el efecto de la Semana Santa —que cambia

de mes cada año y descuadra cualquier comparación mensual—, o segmentar por temporada, que en un negocio de bicicletas explica más varianza que ninguna otra variable.

8.6. Aditividad de las métricas

Aquí está el contenido de este capítulo que evita más errores reales en cuadros de mando de producción.

No todas las métricas se comportan igual al agregarlas.

Aditivas. Se pueden sumar por todas las dimensiones. Importe, unidades, coste, margen en valor absoluto. Sumar las ventas de todas las tiendas de un mes da la venta del mes, y eso es correcto.

Semiaditivas. Se pueden sumar por unas dimensiones y por otras no. El caso típico es el **stock**: sumar el stock de todas las tiendas de un día da el stock total de ese día, que es correcto. Sumar el stock de todos los días del mes da un número sin ningún significado. Por la dimensión tiempo, el stock no se suma: se promedia, o se toma el valor final del período.

No aditivas. No se pueden sumar por ninguna dimensión. Y aquí está el gran grupo peligroso: **todos los ratios, porcentajes y medias**.

Margen %	Ticket medio	Tasa de conversión	Satisfacción media
----------	--------------	--------------------	--------------------

Un porcentaje no se suma. Y —esto es lo que casi nadie tiene presente— **un porcentaje tampoco se promedia**.

8.7. El error de la media de medias

Es el error número uno en cuadros de mando reales. Cinco tiendas de Rueda Libre:

Tienda	Ventas	Margen €	Margen %
Valencia	400.000	60.000	15,0 %
Zaragoza	100.000	18.000	18,0 %
Bilbao	50.000	10.000	20,0 %
Sevilla	30.000	6.600	22,0 %
Vigo	20.000	5.000	25,0 %

Si el cuadro de mando calcula el margen de la cadena promediando la columna de porcentajes:

$(15 + 18 + 20 + 22 + 25) / 5 = 20,0 \%$

Y el margen real de la cadena es:

$$99.600 / 600.000 = 16,6 \%$$

Casi cuatro puntos de diferencia. Y no en un ejercicio de clase: en el indicador que la dirección usa para decidir la política de precios de todo el año.

La causa es que el promedio simple trata igual a Valencia, que hace el 67 % de la facturación, y a Vigo, que hace el 3 %. Las tiendas pequeñas, que casualmente son las de mayor margen porcentual, arrastran el indicador hacia arriba.

La solución correcta es una de estas dos, que son equivalentes:

Recalcular el ratio desde los totales —siempre la mejor opción:

$$\text{Margen \% de la cadena} = \Sigma \text{margen €} / \Sigma \text{ventas €} = 16,6 \%$$

O usar una media ponderada, cuando sólo se dispone de los porcentajes y los pesos:

$$\begin{aligned} & \Sigma (\text{margen\%}_i \times \text{ventas}_i) / \Sigma \text{ventas}_i \\ &= (15 \times 400.000 + 18 \times 100.000 + 20 \times 50.000 + 22 \times 30.000 + 25 \times 20.000) / 600.000 \\ &= 16,6 \% \end{aligned}$$

⚠ La regla práctica, que conviene escribir en la pared del equipo de BI:

Los ratios no se agregan: se recalculan. Se guardan en la tabla de hechos el numerador y el denominador por separado, y el ratio se calcula en el momento de la consulta, al nivel de agregación que se esté mostrando.

Es decir: en `HECHO_VENTAS` se guardan `importe` y `margen`, nunca `margen_%`. El porcentaje se define como una medida calculada. Así, cualquiera que sea el filtro o el nivel de detalle, el número sale bien.

El mismo error, con otras caras:

- Promediar el ticket medio de doce meses para obtener el ticket medio del año.
- Promediar tasas de conversión de campañas de tamaños muy distintos.
- Promediar la satisfacción media de tiendas con volúmenes de encuestas distintos.
- Promediar porcentajes de cumplimiento de objetivo de tiendas desiguales.

8.8. Cubos y operaciones OLAP

Un **cubo multidimensional** es la estructura que materializa el modelo dimensional para consulta rápida: los hechos organizados por las dimensiones, con las agregaciones precalculadas en cada nivel de cada jerarquía.

La metáfora del cubo viene de tres dimensiones —producto, tiempo y tienda— pero un cubo real tiene tantas como haga falta. Cada celda contiene el valor de las métricas para una combinación concreta.

Las operaciones que se hacen sobre un cubo, que son literalmente las que hace cualquier usuario en un cuadro de mando:

Drill-down. Bajar un nivel en una jerarquía. De región a provincia, de provincia a ciudad, de ciudad a tienda. Es la operación diagnóstica por excelencia: «las ventas de la región Este han caído» → *drill-down* → «no ha caído la región: ha caído una tienda».

Drill-up o *roll-up*. Subir un nivel. Agrega el detalle.

Slice. Fijar el valor de una dimensión y quedarse con la «rebanada»: sólo el mes de abril.

Dice. Filtrar por varias dimensiones a la vez: bicicletas, en la región Este, en el segundo trimestre.

Pivot. Girar el cubo: intercambiar qué dimensión va en filas y cuál en columnas.

Estas cinco operaciones son todo lo que hace un usuario de negocio delante de un cuadro de mando. Que las pueda hacer con fluidez depende por completo de que las jerarquías estén bien definidas en el modelo.

8.9. ROLAP, MOLAP y HOLAP

Son tres formas históricas de implementar un cubo. Conviene conocerlas porque aparecen en el temario y en la documentación de sistemas heredados, y porque explican por qué las herramientas actuales son como son.

MOLAP (*Multidimensional OLAP*). El cubo se almacena en una estructura multidimensional propia, con todas las agregaciones precalculadas. Consultas muy rápidas, procesamiento largo, poca flexibilidad y límite de volumen.

ROLAP (*Relational OLAP*). No hay cubo físico: las consultas se traducen a SQL contra el modelo en estrella de una base de datos relacional. Escala mucho mejor y es más lento en consulta.

HOLAP (*Hybrid OLAP*). Combina ambos: los agregados en estructura multidimensional y el detalle en la base relacional.

Qué queda de todo esto hoy. La distinción ha perdido casi toda su relevancia práctica, por dos motivos:

1. Los **motores columnares en memoria** —la tecnología que hay debajo de Power BI, Tableau o Analysis Services tabular— comprimen y consultan tan rápido que la necesidad de precalcular agregaciones ha desaparecido en la mayoría de los casos.
2. Los **almacenes en la nube** escalan el cálculo bajo demanda, de forma que el enfoque relacional dejó de ser el lento.

Es un buen ejemplo de cómo envejece la tecnología en BI: los tres acrónimos siguen en todos los temarios y la decisión que representaban ya casi no se toma. El concepto que sí sobrevive intacto es el de cubo como **modelo lógico**: hechos, dimensiones, jerarquías y agregaciones.

Ejercicios del capítulo 8

- 8.1.** Define el grano de `HECHO_REPARACIONES` para Rueda Libre. Justifícalo y di qué pregunta dejaría de poder responderse si se eligiera un grano más grueso.
- 8.2.** Clasifica cada métrica como aditiva, semiaditiva o no aditiva: unidades vendidas · importe neto · stock a fin de día · margen % · ticket medio · número de clientes distintos · tiempo medio de reparación · coste de las piezas. Presta especial atención al número de clientes distintos: ¿por qué es un caso particular?
- 8.3.** Con los datos del apartado 8.7, calcula el margen porcentual de la cadena por los dos métodos y explica en una frase, apta para un comité de dirección, por qué el 20 % es falso.
- 8.4.** Diseña la dimensión `DIM_PRODUCTO` de Rueda Libre con al menos dos jerarquías distintas. ¿Qué pregunta de negocio responde cada una?
- 8.5.** El responsable de compras quiere analizar el stock por mes. Explica qué pasa si la herramienta suma el stock diario y propón la agregación correcta.
- 8.6.** La región comercial de una tienda cambia a mitad de año. Explica qué mostraría el informe anual de ventas por región con una dimensión de tipo 1 y qué mostraría con una de tipo 2. ¿Cuál es «la correcta»?
-

9. Analizar: relaciones y segmentación

Hasta aquí se ha trabajado con una variable cada vez. Eso es el análisis univariante, y es imprescindible para entender la estructura de los datos y detectar anomalías. Pero la información que cambia decisiones aparece cuando se estudian las **relaciones entre variables**.

9.1. El análisis exploratorio

Antes de cualquier modelo, cualquier indicador y cualquier cuadro de mando, se mira el dato. Es un paso obligatorio, no opcional, y consiste en algo tan poco sofisticado como esto:

1. ¿Cuántas filas hay? ¿Cuántas se esperaban?
2. Para cada variable: escala de medida, valores distintos, nulos, mínimo y máximo.
3. Para cada variable cuantitativa: media, mediana, cuartiles, histograma.
4. Para cada variable cualitativa: tabla de frecuencias.
5. ¿Qué valores son imposibles? ¿Qué valores son sospechosos?
6. ¿La distribución tiene la forma que cabría esperar del negocio?

El análisis exploratorio no busca respuestas: busca sorpresas. La mitad de los problemas de calidad de un proyecto de BI se detectan en este paso, y detectarlos aquí cuesta cien veces menos que detectarlos en el comité de dirección.

9.2. Segmentación

Segmentar es dividir el conjunto en grupos con comportamiento homogéneo y analizarlos por separado. Es la técnica diagnóstica más rentable que existe, y casi siempre es la respuesta correcta cuando un indicador global no cuadra.

En Rueda Libre, el ticket medio de la cadena es 128 €. Segmentando:

Segmento	Tickets	Ticket medio
Accesorios y ropa	1.980	41 €
Componentes y taller	410	112 €
Bicicleta completa	310	1.020 €

El 128 € de la cadena no describe a **ningún** cliente real. Es el resultado aritmético de mezclar tres negocios distintos. La distribución multimodal del capítulo 4 era la señal de alarma; la segmentación es la respuesta.

Criterios de segmentación habituales: por producto, por canal, por geografía, por tipo de cliente, por temporada, por tamaño de operación.

9.3. Comparar poblaciones equivalentes

La pregunta que abría el caso —«¿por qué Valencia vende más que Zaragoza si son del mismo tamaño?»— contiene una trampa. «Del mismo tamaño» se refería a los metros cuadrados de local. Pero:

	Valencia	Zaragoza
Superficie	220 m ²	215 m ²
Población del área	800.000	650.000
Años abierta	12	3
Renta media del barrio	Alta	Media
Aparcamiento	Sí	No
Carril bici en la calle	Sí	No

Las dos tiendas no son comparables en nada excepto en superficie. Cualquier conclusión sobre la gestión de sus responsables extraída de la diferencia de ventas es injusta y probablemente falsa.

Antes de comparar dos cifras hay que preguntarse qué hace falta que sea igual para que la comparación signifique algo. Casi nunca se cumple del todo.

La solución práctica es **normalizar**: en lugar de comparar ventas absolutas, comparar ventas por metro cuadrado, por habitante del área de influencia, o por empleado. Cada normalización responde a una pregunta distinta y ninguna es neutra.

9.4. La paradoja de Simpson

Es el caso extremo de lo anterior, y merece conocerse porque produce conclusiones exactamente contrarias a la realidad.

Rueda Libre lanza una campaña de descuento en dos tiendas. Tasa de conversión de visita a venta:

	Valencia	Zaragoza	TOTAL
Con campaña	70/100 = 70 %	18/300 = 6 %	88/400 = 22 %
Sin campaña	27/300 = 9 %	80/100 = 80 %	107/400 = 27 %

Mirando el total, la campaña **empeora** la conversión: 22 % frente a 27 %. Mirando cada tienda por separado, la campaña **mejora** la conversión en las dos: 70 % frente a 9 % en Valencia, y 6 % frente a 80 %... no, ahí también empeora.

Rehagamos el ejemplo con números limpios, que es como se ve mejor:

	Valencia	Zaragoza	TOTAL
Con campaña	63/70 = 90 %	10/50 = 20 %	73/120 = 61 %
Sin campaña	27/30 = 90 %	36/180 = 20 %	63/210 = 30 %

En cada tienda la conversión es **idéntica** con y sin campaña. Pero en el total, la campaña parece duplicar la conversión. La causa es que la campaña se concentró en Valencia, que convierte mucho mejor por razones que nada tienen que ver con la campaña.

La agregación puede invertir o inventar una relación. Cuando un total dice una cosa y los segmentos dicen otra, hay una variable oculta que está desequilibrando los grupos.

⚠ Esta es la razón por la que un cuadro de mando que sólo muestra totales es peligroso: no permite detectar el problema. La capacidad de hacer *drill-down* no es una comodidad, es un requisito de fiabilidad.

9.5. Correlación

La correlación mide en qué grado dos variables cuantitativas varían conjuntamente. Se expresa con un coeficiente entre -1 y $+1$:

+1	relación lineal positiva perfecta
+0,7	relación positiva fuerte
+0,3	relación positiva débil
0	sin relación lineal
-0,7	relación negativa fuerte
-1	relación lineal negativa perfecta

En Rueda Libre, la correlación entre la temperatura media diaria y las ventas de bicicleta es de $+0,68$: cuando sube la temperatura, sube la venta.

Tres advertencias que hay que dar siempre a la vez:

Mide relación lineal. Una correlación de 0 no significa que no haya relación: significa que no hay relación *lineal*. La venta de bicicletas frente a la temperatura no es lineal a partir de cierto punto: a 42 °C nadie sale a pedalear. Un diagrama de dispersión enseña en un segundo lo que el coeficiente esconde.

Es sensible a los atípicos. Un solo Manolo puede crear o destruir una correlación. Siempre se mira el diagrama de dispersión antes de creerse el número.

Correlación no es causalidad. Es la advertencia más repetida del análisis de datos y la más ignorada en la práctica.

9.6. Correlación y causalidad

Que dos variables se muevan juntas admite cuatro explicaciones distintas, y sólo una es la que la gente asume:

1. **A causa B.** La temperatura hace que se venda más bicicleta.
2. **B causa A.** La relación es la inversa de la que se suponía.
3. **Una tercera variable causa las dos.** Es la *variable de confusión*.
4. **Casualidad.** Con suficientes variables, siempre aparecen correlaciones altas sin ningún significado.

El caso 3 es el que más daño hace en la práctica. En Rueda Libre:

Observación: las tiendas con más empleados venden más.
Conclusión: contratemos más gente en todas las tiendas.
Realidad: las tiendas con más población en su área tienen más empleados
Y más ventas. La población es la variable de confusión.

Contratar dos empleados más en Vigo no aumentará sus ventas, porque no era la plantilla lo que las causaba.

Para afirmar causalidad hacen falta tres condiciones, y ninguna la da la correlación por sí sola:

- **Precedencia temporal:** la causa ocurre antes que el efecto.
- **Asociación:** cuando varía la causa, varía el efecto.
- **Ausencia de explicación alternativa:** se han descartado las variables de confusión.

La única forma limpia de establecer causalidad es el **experimento controlado**: asignar al azar quién recibe el tratamiento y quién no. En negocio se llama prueba A/B, y es perfectamente factible para una cadena de tiendas: aplicar la campaña en seis tiendas elegidas al azar y no en las otras seis.

Si una decisión importante depende de una relación causal, hay que hacer el experimento. Si no se puede hacer, hay que decir explícitamente que la relación es una hipótesis y no un hecho.

Ejercicios del capítulo 9

9.1. El cuadro de mando muestra que el ticket medio de la cadena ha caído un 8 %. Diseña la secuencia de segmentaciones que harías, en orden, para averiguar qué ha pasado. ¿Por qué en ese orden?

9.2. Se observa que las reparaciones que entran los lunes tardan más en resolverse. Propón tres explicaciones distintas —una de cada tipo de los cuatro del apartado 9.6— y di qué dato pedirías para distinguir entre ellas.

9.3. Un análisis encuentra correlación de $+0,82$ entre las ventas de ropa técnica y las de cascos. ¿Se puede concluir que promocionar cascos aumentará la venta de ropa? ¿Qué prueba diseñarías para averiguarlo?

9.4. Construye un ejemplo numérico propio de paradoja de Simpson con los datos de Rueda Libre, distinto del del manual.

9.5. «Las tiendas que abren los domingos venden un 22 % más.» Enumera cuatro razones por las que esa cifra podría no justificar abrir todas las tiendas los domingos.

10. Minería de datos

10.1. Qué es y qué no es

La **minería de datos** es el conjunto de técnicas que buscan patrones en grandes volúmenes de datos de forma automática o semiautomática.

La diferencia con todo lo anterior está en el punto de partida. En estadística descriptiva y en reporting, la pregunta la formula una persona y los datos responden. En minería de datos, es el algoritmo el que propone la pregunta: busca estructura que nadie había pedido.

Lo que no es:

- No es magia: sobre datos malos produce patrones malos, con más convicción.
- No sustituye al conocimiento del negocio: un patrón sin interpretación es ruido.
- No es lo mismo que aprendizaje automático, aunque comparte casi todas las técnicas. La minería de datos es la disciplina orientada a **descubrir** conocimiento; el aprendizaje automático, la familia de algoritmos que se usa para ello y también para **predecir**.

La minería de datos encuentra patrones. Decidir cuáles de esos patrones son conocimiento y cuáles casualidad sigue siendo trabajo de una persona que entienda el negocio.

10.2. Las categorías

Cada técnica resuelve un tipo de problema distinto. Lo importante en este curso no es saber implementarlas, sino saber **cuál pedir** ante un problema de negocio.

Clasificación. Asignar cada individuo a una categoría conocida de antemano. Es aprendizaje *supervisado*: se necesitan ejemplos ya etiquetados.

Rueda Libre: ¿Este cliente va a darse de baja en los próximos tres meses?
¿Esta reparación va a superar el plazo comprometido?
¿Este pedido web es fraudulento?

Regresión. Igual que la clasificación, pero la salida es un número en lugar de una categoría.

Rueda Libre: ¿Cuántas unidades de este modelo venderemos el mes que viene?
¿Cuánto tardará esta reparación?
¿Cuál es el valor esperado de este cliente a tres años?

Agrupamiento (*clustering*). Descubrir grupos naturales sin saber de antemano cuáles son ni cuántos. Es aprendizaje *no supervisado*.

Rueda Libre: ¿Qué tipos de cliente existen realmente en nuestra base?

Es especialmente valioso porque suele contradecir la segmentación que la empresa creía tener. Rueda Libre segmentaba por importe de compra; el agrupamiento reveló que los grupos con comportamiento homogéneo eran otros: el ciclista de competición, el cliente urbano de trayecto diario, el comprador de regalo y el aficionado de fin de semana. Cuatro grupos con necesidades, márgenes y estacionalidades distintas.

Reglas de asociación. Encontrar qué cosas ocurren juntas. Es el clásico análisis de la cesta de la compra.

Rueda Libre: «Quien compra una bicicleta de montaña compra casco en el 62 % de los casos, pero guantes sólo en el 11 %.»

De ahí salen decisiones concretas de colocación en tienda, de recomendación en la web y de paquetes de venta.

Detección de anomalías. Identificar lo que se sale del patrón. Es el capítulo 5 convertido en algoritmo y aplicado en continuo.

Rueda Libre: Un TPV que registra devoluciones fuera de lo habitual.
Una carga nocturna con un volumen anómalo.
Un sensor de la web con un pico de tráfico no humano.

Análisis de secuencias. Como las reglas de asociación, pero incorporando el orden temporal: qué compra un cliente *después* de qué.

10.3. El proceso de minería de datos

Las fases, en orden:


1. **Selección.** Decidir qué datos entran en el análisis y cuáles no.
2. **Preparación.** Limpiar, tratar nulos y atípicos, unificar formatos.
3. **Transformación.** Derivar variables nuevas, normalizar escalas, codificar variables cualitativas, reducir dimensiones.
4. **Modelado.** Aplicar el algoritmo y ajustar sus parámetros.
5. **Evaluación.** Medir si el modelo funciona sobre datos que no ha visto, e interpretar si el patrón tiene sentido de negocio.

6. **Despliegue.** Poner el resultado en producción, donde alguien lo use.

⚠ Las fases 1 a 3 se llevan entre el 60 % y el 80 % del tiempo total. La fase 4, la única que la gente asocia con la minería de datos, suele ser la más corta.

10.4. CRISP-DM

Es la metodología estándar del sector. Añade a lo anterior dos cosas imprescindibles: empieza por el negocio y es **cíclica**.



Dos rasgos que la hacen útil:

- **Empieza por el negocio, no por los datos.** La primera fase no consiste en mirar tablas: consiste en averiguar qué decisión hay que mejorar y cómo se sabrá si el proyecto ha servido para algo.
- **Los bucles son la norma.** De modelado se vuelve a preparación constantemente, y de evaluación se vuelve al negocio cuando resulta que el problema estaba mal planteado. Un proyecto de minería

que avanza en línea recta es un proyecto que no está aprendiendo nada.

10.5. Sobreajuste y validación

Un modelo puede aprenderse los datos de memoria en lugar de aprender el patrón. Eso es el **sobreajuste**: funciona perfectamente sobre los datos con los que se construyó e inútilmente sobre datos nuevos.

La defensa mínima es separar los datos:

ENTRENAMIENTO	(70 %)	Se construye el modelo
VALIDACIÓN	(15 %)	Se ajustan los parámetros
PRUEBA	(15 %)	Se mide el resultado final. Se usa UNA vez.

Y en series temporales, la separación **no puede ser aleatoria**: hay que entrenar con el pasado y validar con el futuro. Entrenar un modelo de demanda con datos de diciembre para predecir noviembre es hacer trampa, y da resultados excelentes que no sobreviven a la producción.

Un modelo con un 99 % de acierto es casi siempre una mala noticia: o hay sobreajuste, o se ha colado en las variables de entrada alguna que contiene implícitamente la respuesta.

El segundo caso tiene nombre —*fuga de información*— y es un error frecuente. Predecir si una reparación se va a retrasar usando como variable la fecha de salida real da un acierto perfecto y no sirve para nada: en el momento en que hay que predecir, esa fecha todavía no existe.

⚠ El acierto global tampoco basta cuando las clases están desequilibradas. Si sólo el 2 % de los clientes se da de baja, un modelo que prediga «nadie se va a dar de baja» acierta el 98 % de las veces y es completamente inútil. Hay que mirar cuántas bajas reales detecta y cuántas falsas alarmas genera.

Ejercicios del capítulo 10

10.1. Para cada necesidad de Rueda Libre, indica qué categoría de minería de datos corresponde: (a) saber qué clientes están a punto de dejar de comprar; (b) descubrir qué tipos de cliente hay realmente; (c) saber qué productos conviene colocar juntos; (d) estimar la venta de la próxima temporada; (e) detectar un TPV que está registrando operaciones raras.

10.2. Un modelo predice con un 96 % de acierto qué reparaciones se retrasarán. Al revisar las variables se descubre que una de ellas es «número de veces que se ha llamado al cliente para avisar del retraso». ¿Qué está pasando? ¿Cómo se llama?

10.3. El agrupamiento de clientes de Rueda Libre devuelve cuatro grupos. ¿Cómo decidirías si esos grupos son útiles o son un artefacto del algoritmo? Da dos criterios: uno estadístico y uno de negocio.

10.4. Explica por qué en un modelo de predicción de demanda no se puede repartir la muestra al azar entre entrenamiento y prueba. Propón la alternativa correcta.

10.5. La dirección quiere empezar un proyecto de minería de datos. Aplicando CRISP-DM, escribe las tres preguntas que harías en la fase 1 antes de mirar un solo dato.

11. Indicadores, informes y cuadros de mando

Todo lo anterior sirve para llegar hasta aquí: el momento en que el análisis se convierte en algo que alguien mira y con lo que alguien decide.

11.1. Métrica y KPI

No son sinónimos, aunque se usen como tales.

Una **métrica** es cualquier cosa que se puede medir. Un **KPI** (*Key Performance Indicator*) es una métrica que mide el avance hacia un objetivo y que **cambia una decisión**.

La prueba es sencilla y despiadada:

Si el indicador sube o baja, ¿alguien hace algo distinto? Si la respuesta es no, no es un KPI: es decoración.

En un cuadro de mando típico, entre el 50 % y el 70 % de lo que hay no pasa esta prueba. «Número de visitas a la web» es una métrica; «tasa de conversión de visita a venta» puede ser un KPI, si alguien tiene capacidad de actuar sobre ella.

Indicadores accionables frente a métricas decorativas. Un indicador accionable cumple cuatro condiciones: alguien es responsable de él, alguien puede influir en él, hay un objetivo o una referencia, y existe una acción prevista si se desvía.

11.2. La definición operativa

Un KPI no está definido hasta que están escritas estas siete cosas:

Nombre	Ticket medio
Pregunta	¿Cuánto gasta un cliente por operación?
Fórmula	Importe neto total / número de tickets
Fuente	HECHO_VENTAS, capa de presentación
Grano	Un ticket. Excluye traspasos entre tiendas.
Filtros	Excluye devoluciones y ventas a empleados
Período	Mes natural, por fecha de cobro
Responsable	Dirección comercial

Sin esto, el mismo nombre significa cosas distintas en departamentos distintos. En Rueda Libre, «ventas» significaba cuatro cosas:

Comercial	Importe con IVA, en el momento del pedido
Finanzas	Importe sin IVA, en el momento del cobro
Tienda	Todo lo que pasa por caja, traspasos incluidos
Web	Pedidos confirmados, incluidos los que luego se cancelan

Las cuatro son razonables. Ninguna es la buena. Lo que no es aceptable es que convivan sin que nadie lo sepa: dos personas llegan a la misma reunión con dos cifras y la discusión pasa de qué hacer a quién tiene razón.

La tarea más rentable de un proyecto de BI no es técnica: es conseguir que la organización acuerde una definición por indicador y la escriba.

11.3. Absolutos, relativos, ratios y tasas

Un **indicador absoluto** cuenta magnitud: 142.000 € de venta. Un **indicador relativo** la pone en contexto: 108 % del objetivo, +12 % interanual, 645 € por m².

Se necesitan los dos. El absoluto dice el tamaño; el relativo, si es bueno.

Los ratios y las tasas son donde se miente, casi siempre en el denominador.

Tasa de conversión = ventas / visitas

Parece incontrovertible. Pero: ¿visitas o visitantes únicos? ¿Se cuentan los robots? ¿Y quien entra a consultar el horario? ¿Y quien compra por teléfono después de visitar la web, en qué canal cuenta?

Cambiando la definición del denominador, la misma tasa pasa del 2 % al 7 % sin que haya cambiado nada en el negocio. Por eso la definición operativa incluye la fuente y los filtros: no es burocracia.

⚠ Dos avisos concretos sobre porcentajes:

Base pequeña. «La tienda de Vigo ha mejorado su conversión un 200 %» suena espectacular hasta que se ve que pasó de 1 venta a 3. Un porcentaje sin su valor absoluto al lado es una cifra incompleta.

Puntos porcentuales frente a porcentaje. Pasar del 15 % al 18 % de margen es una subida de **3 puntos porcentuales**, o del **20 %** en términos relativos. Las dos frases son correctas y describen lo mismo; usarlas indistintamente confunde a todo el mundo, y elegir la más favorable es una forma habitual de exagerar un resultado.

11.4. La media de medias, otra vez

El capítulo 8 explicó por qué los ratios no se agregan. Aquí es donde el error aparece: en el cuadro de mando.

Los síntomas de que está ocurriendo:

- El total de la fila «Cadena» no coincide con lo que sale al calcularlo a mano.
- El indicador cambia al aplicar un filtro que no debería afectarle.
- El valor de la cadena está fuera del rango de los valores de las tiendas — imposible en una media ponderada, habitual en una media simple mal hecha.

La solución, ya vista, es guardar numerador y denominador y definir el ratio como medida calculada. Es una decisión de modelado que se toma en el capítulo 8 y cuyo efecto se ve aquí.

Otros casos del mismo error, todos frecuentes:

```
Ticket medio del año      ≠ media de los doce ticket medio mensuales
Conversión de la campaña ≠ media de las conversiones por tienda
Satisfacción global       ≠ media de las satisfacciones por tienda
Cumplimiento de la cadena ≠ media de los cumplimientos por tienda
```

11.5. El contexto

Un número solo no significa nada. «142.000 €» no es bueno ni malo.


Un indicador necesita al menos una referencia, y preferiblemente varias:

- **Objetivo.** ¿Cuánto se esperaba?
- **Período anterior.** ¿Cómo va respecto al mes pasado?
- **Mismo período del año anterior.** Imprescindible en negocios estacionales, y en bicicletas lo es de forma extrema: comparar julio con junio no dice nada.
- **Referencia externa.** ¿Cómo va el sector?
- **Distribución.** ¿Cómo se reparte entre tiendas, productos o clientes?

Y la regla que enlaza con todo el bloque estadístico:

Ningún indicador de tendencia central se publica sin su dispersión. En un cuadro de mando, eso significa que junto a la media va la mediana, un percentil alto, o el rango entre el mejor y el peor.

En Rueda Libre, la tarjeta del tiempo de reparación quedó así:



Tres cifras y una distribución, en el espacio que ocupaba un solo número. Y ahora la tarjeta permite decidir: el problema no es el tiempo típico, es la cola.

11.6. Informes, consultas y alertas

Además del cuadro de mando, un sistema de BI entrega información de otras tres formas, y cada una tiene su momento.

Informes. Documentos estructurados, con periodicidad fija y destinatarios definidos. Siguen siendo la respuesta correcta cuando hay que dejar constancia, cuando el destinatario no va a entrar en ninguna herramienta, o cuando el contenido es regulatorio. Se distingue entre informes *operativos* —el listado de reparaciones pendientes— e informes *analíticos* —el cierre mensual comentado.

Consultas. El acceso directo a los datos para responder preguntas no previstas. Tres modelos:

- *Ad hoc por el equipo de BI:* control total, cuello de botella garantizado.
- *Autoservicio libre:* rapidez y caos; cada usuario construye su versión de la verdad.
- *Autoservicio gobernado:* los usuarios construyen sus análisis, pero sobre un modelo semántico común con las métricas ya definidas. Es la opción recomendable, y la que hace que la definición operativa del apartado 11.2 sea rentable.

Alertas. Avisos automáticos cuando un indicador cruza un umbral. Requisitos para que funcionen:

- Umbral justificado, no elegido a ojo. Un umbral estadístico —más de 2σ sobre la media histórica— envejece mucho mejor que un número fijo.
- Destinatario con capacidad de actuar.
- **Acción prevista.** Una alerta sin acción asociada es ruido.
- Volumen controlado. La *fatiga de alertas* es real: un sistema que avisa veinte veces al día deja de leerse en una semana, y entonces también se pierde la que importaba.

11.7. Diseñar un cuadro de mando

Un cuadro de mando no es una colección de gráficos. Las preguntas a responder **antes** de abrir la herramienta:

1. ¿Quién lo va a mirar? Un cuadro sirve a una audiencia, no a tres.
2. ¿Con qué frecuencia?
3. ¿Qué decisión permite tomar?
4. ¿Qué hace esa persona si el indicador se pone en rojo?
5. ¿Qué es lo primero que tiene que ver al abrirlo?

De la audiencia sale el nivel, volviendo a la pirámide del capítulo 1:

	Estratégico	Táctico	Operativo
Audiencia	Dirección	Responsable de tienda	Encargado de turno
Horizonte	Años y trimestres	Meses y semanas	Hoy
Indicadores	5 a 8	10 a 15	Los que caben en una pantalla
Detalle	Muy agregado	Agregado con drill-down	Registro individual
Actualización	Mensual	Diaria	Continua

Principios de composición:

- **Resumen arriba, detalle abajo.** Lo primero que se ve responde a «¿va bien o mal?». El detalle está para quien pregunta por qué.
- **Máximo tres niveles de lectura:** estado, evolución, desglose.
- **Codificar el estado en la forma, no sólo en el número.** Un color, un símbolo, una banda. Debe leerse sin leer.
- **La navegación en profundidad no es un extra.** Es lo que evita la paradoja de Simpson.
- **Todo indicador lleva su definición accesible.** Un icono de información con la fórmula, la fuente y el período.

11.8. Visualización honesta

Elegir el gráfico según la escala de medida, que es el cierre del capítulo 2:

Qué se quiere mostrar	Gráfico
Comparar categorías	Barras
Composición de un todo	Barras apiladas al 100 % · sectores si son pocas
Evolución en el tiempo	Líneas
Distribución de una variable continua	Histograma · caja y bigotes
Relación entre dos cuantitativas	Dispersión
Comparar distribuciones entre grupos	Cajas múltiples · violines
Un valor contra su objetivo	Barra con marcador de objetivo

Las trampas más habituales, que conviene saber detectar tanto en los cuadros propios como en los ajenos:

Eje truncado. Empezar el eje vertical en 95 en lugar de en 0 convierte una variación del 2 % en un precipicio. En gráficos de barras el eje debe empezar en cero, porque la longitud de la barra codifica la magnitud. En gráficos de líneas, donde lo que importa es la variación, truncar es aceptable si se indica.

Doble eje. Dos series con escalas distintas en el mismo gráfico: moviendo las escalas se puede hacer que parezcan correlacionadas o independientes a voluntad.

Sectores con demasiadas categorías. Ocho porciones son ilegibles. Y el efecto 3D distorsiona las áreas: la porción de delante siempre parece mayor.

Escala temporal irregular. Puntos no equiespaciados en el eje X que sugieren tendencias inexistentes.

Exceso de color. Si todo está coloreado, el color deja de significar nada. El color se reserva para codificar información: estado, categoría, atención.

Agregación que oculta. Un total que esconde una caída fuerte en un segmento. Es la razón del drill-down.

Un cuadro de mando visualmente atractivo y conceptualmente falso es más peligroso que una hoja de cálculo fea: se cree más y se cuestiona menos.

Ejercicios del capítulo 11

11.1. Escribe la definición operativa completa —las siete líneas— del indicador «tasa de devolución» de Rueda Libre. Toma las decisiones que hagan falta y déjalas explícitas.

11.2. El cuadro de mando muestra «Margen de la cadena: 20 %». Las tiendas van del 15 % al 25 %. Explica cómo detectarías si está mal calculado, sin acceso a los datos de detalle.

11.3. Diseña la tarjeta del indicador «ticket medio» siguiendo el modelo del apartado 11.5. ¿Qué tres cifras pondrías y por qué?

11.4. De estos seis indicadores, señala cuáles son KPI y cuáles decoración, justificando con la prueba del apartado 11.1: número de visitas a la web · tasa de conversión · seguidores en redes · margen por familia · número de referencias en catálogo · porcentaje de reparaciones fuera de plazo.

11.5. Un gráfico de barras muestra las ventas mensuales con el eje vertical empezando en 130.000. La variación real entre el mejor y el peor mes es del 6 %. Describe qué impresión da el gráfico y cómo lo corregirías.

11.6. Diseña una alerta útil para el jefe de taller: qué mide, con qué umbral, a quién avisa y qué acción dispara. Después explica por qué el umbral que has elegido es mejor que un número fijo.

12. Series temporales y pronósticos

12.1. Describir no es predecir

Son dos oficios distintos.

	Descripción	Predicción
Pregunta	¿Qué ha pasado?	¿Qué va a pasar?
Datos	Los observados	Los observados, para inferir los futuros
Validación	Que el cálculo sea correcto	Que acierte sobre datos no vistos
Resultado	Un hecho	Una estimación con incertidumbre
Si se equivoca	Estaba mal el dato	Puede estar todo bien y aun así fallar

Un pronóstico sin margen de error no es un pronóstico: es una opinión con decimales.

12.2. Los componentes de una serie temporal

Una serie temporal —una variable medida a lo largo del tiempo— se descompone conceptualmente en cuatro partes:

Tendencia. El movimiento de fondo a largo plazo. Rueda Libre crece un 4 % anual.

Estacionalidad. El patrón que se repite con período fijo y conocido. En bicicletas es brutal: abril a septiembre concentra el 68 % de la venta anual. Hay estacionalidad a varias escalas: anual, mensual (los días de cobro), semanal (sábado es el mejor día) y hasta diaria.

Ciclo. Oscilaciones de período largo e irregular, típicamente ligadas a la economía. Se distingue de la estacionalidad en que su duración no es fija.

Ruido. Lo que queda. Variación aleatoria sin patrón.

$$\text{Serie observada} = \text{Tendencia} + \text{Estacionalidad} + \text{Ciclo} + \text{Ruido}$$

La utilidad práctica de la descomposición es inmediata: permite responder a «¿hemos crecido de verdad, o es que era verano?».

12.3. Comparar períodos

Es el punto donde más se equivocan los cuadros de mando reales.

«Las ventas han caído un 31 % respecto al mes pasado»

Si el mes pasado era agosto y éste es septiembre, en una cadena de bicicletas esa frase no aporta ninguna información: la caída es estacional y ocurre todos los años.

Las formas correctas de comparar, cada una con su uso:

Interanual (mismo mes del año anterior). Elimina la estacionalidad de golpe. Es la comparación por defecto en negocios estacionales.

Septiembre 2026 frente a septiembre 2025: +6 % ← esto sí informa

⚠ Con un aviso: si el año anterior fue anómalo, la comparación hereda la anomalía. Comparar contra un mes en que la tienda estuvo cerrada por obras produce crecimientos espectaculares y falsos.

Acumulado del año. Suaviza el ruido mensual y mide el avance hacia el objetivo anual.

Media móvil. El promedio de los últimos n períodos. Con $n = 12$ en datos mensuales elimina la estacionalidad y deja ver la tendencia limpia. Es la herramienta más simple y más útil de todo el capítulo.

Frente a objetivo. La comparación que más le importa a quien tiene que rendir cuentas.

12.4. Señal y ruido

El error operativo más caro no es de cálculo: es reaccionar a cada punto del gráfico.

Una serie con ruido sube y baja continuamente sin que nada haya cambiado. Si cada subida provoca una felicitación y cada bajada una reunión de urgencia, la organización se agota persiguiendo variaciones aleatorias.

La forma de distinguir:

- Mirar la **variabilidad histórica**. Si la serie oscila habitualmente $\pm 8\%$ y este mes ha bajado un 5 %, no ha pasado nada.
- Exigir **persistencia**. Un punto no es una tendencia. Tres períodos consecutivos en la misma dirección empiezan a serlo.
- Usar **límites de control**: media histórica $\pm 2\sigma$. Dentro de esa banda, es ruido; fuera, merece investigación. Es el mismo criterio del capítulo 5, aplicado al tiempo.

Antes de explicar por qué ha bajado un indicador, hay que demostrar que ha bajado.

12.5. Modelos sencillos de pronóstico

En orden creciente de sofisticación, y todos comprensibles sin matemáticas:

Ingenuo. El próximo período será igual que el último. Parece una broma y es la referencia obligatoria: cualquier modelo que no supere al ingenio no aporta nada.

Ingenio estacional. El próximo julio será como el julio pasado. En negocios estacionales es sorprendentemente difícil de batir.

Media móvil. El próximo período será el promedio de los últimos n . Suaviza el ruido y va con retraso ante los cambios reales.

Suavizado exponencial. Como la media móvil, pero dando más peso a lo reciente. Sus variantes incorporan tendencia y estacionalidad; es lo que usa la mayoría de los sistemas de previsión de demanda.

Regresión sobre la tendencia. Ajustar una recta —o una curva— a la serie y prolongarla.

⚠ Sobre la regresión, dos avisos. Primero: **extrapolar fuera del rango observado es una apuesta**, no un cálculo; una recta ajustada sobre tres años de crecimiento predice crecimiento indefinido, y ningún negocio crece indefinidamente. Segundo: ajustar bien el pasado no garantiza nada sobre el futuro. Un polinomio de grado alto puede pasar exactamente por todos los puntos históricos y dar predicciones absurdas al período siguiente.

12.6. La incertidumbre

Un pronóstico se comunica siempre con tres elementos:

Valor esperado	Ventas de julio: 148.000 €
Intervalo	Entre 131.000 y 165.000 € (80 % de confianza)
Supuestos	Sin apertura de tiendas nuevas · Sin cambios de precio · Meteorología dentro de lo normal

El intervalo no es una debilidad del modelo: es información. Un rango estrecho permite comprometer stock; uno ancho obliga a preparar dos escenarios.

Y hay una regla que conviene decir siempre: **la incertidumbre crece con el horizonte**. Un pronóstico a un mes puede ser útil; a tres años, con la misma metodología, es un ejercicio de ficción. Cuando alguien pida una previsión a cinco años, lo honesto es entregar escenarios —optimista, central, pesimista— y no una cifra.

12.7. Tamaño de muestra y representatividad

Un porcentaje calculado sobre pocos casos no es un porcentaje: es una anécdota.

La nueva página de producto convierte al 100 %. ← sobre 3 visitas
La tienda de Vigo tiene 5 estrellas de media. ← sobre 2 reseñas
El nuevo modelo se devuelve el 50 % de las veces. ← se han vendido 2

Tres reglas prácticas para un cuadro de mando:

1. Mostrar siempre el tamaño de la muestra junto al porcentaje.
2. Definir un mínimo por debajo del cual el indicador no se publica —se muestra «datos insuficientes».
3. Desconfiar de los extremos. En cualquier ranking, los primeros y los últimos puestos suelen estar ocupados por los grupos más pequeños, simplemente porque varían más.

12.8. Riesgos del pronóstico automatizado

Degradación del modelo. Un modelo entrenado con datos de hace dos años deja de ser válido cuando el negocio cambia. Hay que medir su acierto en continuo y reentrenarlo.

Cambios de régimen. Una pandemia, un cambio de precios, la apertura de un competidor. Ningún modelo entrenado con el pasado los anticipa, y todos siguen prediciendo con total confianza después de que ocurran.

Realimentación. Si el pronóstico determina el pedido de stock, y el stock determina la venta, el modelo acaba prediciendo su propia decisión y no la demanda. Es un bucle difícil de detectar: los indicadores de acierto salen excelentes.

Automatizar una conclusión incorrecta. Es el riesgo mayor y conecta con todo el manual. Un error de definición de indicador ejecutado una vez es un error. El mismo error dentro de un proceso automático se ejecuta cada noche, alimenta decisiones cada día, y nadie lo revisa porque ya funcionaba.

La automatización no mejora la calidad de un análisis. Multiplica lo que haya: si el razonamiento es bueno, lo escala; si es malo, lo industrializa.

Ejercicios del capítulo 12

12.1. Las ventas de Rueda Libre en octubre caen un 28 % respecto a septiembre. Enumera las tres comprobaciones que harías, en orden, antes de escribir una sola línea de explicación.

12.2. Una misma serie se presenta de cuatro maneras: mensual, interanual, acumulada del año y con media móvil de 12 meses. Explica qué pregunta responde cada una y cuál usarías ante el comité de dirección.

12.3. Diseña el pronóstico de venta de cascos para el próximo trimestre usando el método ingenuo estacional. ¿Qué datos necesitas? ¿Contra qué compararías el resultado de un modelo más sofisticado?

12.4. Redacta el pronóstico de ventas de julio para la dirección, con los tres elementos del apartado 12.6. Inventa las cifras pero sé coherente.

12.5. El cuadro de mando muestra un ranking de tiendas por satisfacción media. Los tres primeros puestos son las tres tiendas más pequeñas. ¿Es casualidad? ¿Cómo lo comprobarías? ¿Cómo cambiarías el cuadro de mando?

12.6. Un modelo de previsión de demanda lleva ocho meses funcionando y su acierto ha bajado del 88 % al 61 %. Enumera cuatro causas posibles y cómo distinguirlas.

13. La gestión de un proyecto de BI

13.1. Por qué no es un proyecto de desarrollo

Un proyecto de BI tiene tres rasgos que lo hacen distinto y que explican por qué las planificaciones clásicas fallan sistemáticamente:

El alcance se descubre trabajando. Nadie sabe qué contiene realmente una fuente de datos hasta que la abre. Un proyecto de BI que promete alcance cerrado antes de haber perfilado los datos está prometiéndole algo que no puede saber.

La mayor parte del esfuerzo está en los datos, no en la herramienta. Construir el cuadro de mando es la parte rápida. Conseguir que las cifras sean correctas es la parte larga.

El valor no está en el entregable, está en el uso. Un cuadro de mando terminado que nadie abre es un proyecto fracasado, aunque cumpliera plazo y presupuesto.

Los proyectos de BI no fracasan por tecnología. Fracasan por preguntas mal planteadas y por definiciones que nadie acordó.

13.2. Las fases

1	Pregunta de negocio	¿Qué decisión hay que mejorar?
2	Audiencia e interlocutores	¿Quién decide y quién sabe?
3	Inventario de fuentes	¿Qué hay y dónde está?
4	Perfilado y calidad	¿Se puede confiar en ello?
5	Propietarios del dato	¿Quién responde de cada cosa?
6	Definición de KPIs	¿Qué significa exactamente cada indicador?
7	Diseño del modelo	Grano, hechos, dimensiones, jerarquías
8	Construcción	ETL, almacén, modelo semántico
9	Validación con usuarios	¿Coincide con lo que ellos saben?
10	Puesta en producción	Orquestación, permisos, formación
11	Evolución	Medir el uso y responder a lo que surja

Dos observaciones sobre el orden:

- **Las fases 1 a 6 no son preliminares: son el proyecto.** Si están bien hechas, la 8 es mecánica. Si están mal hechas, la 8 no las arregla.
- **La 9 no es una formalidad.** La validación consiste en enseñarle al responsable de tienda su propia cifra y ver si la reconoce. Si no la reconoce, hay un problema —de dato, de definición o de

expectativa— y hay que resolverlo antes de publicar.

13.3. Los roles

Rol	Quién es	De qué responde
Patrocinador	Dirección	Que el proyecto exista y tenga prioridad
Propietario del dato	Negocio	Qué significa cada dato y quién accede
Usuario clave	Negocio	Validar que las cifras son correctas
Analista de BI	Técnico	Modelo, indicadores, cuadros de mando
Ingeniero de datos	Técnico	Extracción, transformación, carga
Responsable de sistemas	TI	Acceso a las fuentes, infraestructura

Qué pasa cuando falta cada uno:

- Sin patrocinador, el proyecto pierde prioridad ante cualquier urgencia operativa.
- Sin propietario del dato, las decisiones de negocio las toma quien programa.
- Sin usuario clave, se construye algo correcto que nadie reconoce como suyo.
- Sin acceso a las fuentes, todo se retrasa y nadie sabe a quién reclamar.

13.4. Planificación

La estimación realista. El reparto habitual del esfuerzo:

Análisis, definición y acuerdo de KPIs	20 %
Perfilado y calidad de los datos	25 %
Desarrollo de los procesos de carga	30 %
Modelo y cuadros de mando	15 %
Validación, formación y ajustes	10 %

Un plan que dedique la mitad del tiempo a construir cuadros de mando está mal hecho.

Las dependencias críticas casi nunca son técnicas. Son de acceso: permisos para leer una base de datos, disponibilidad de la persona que conoce el sistema antiguo, decisión pendiente sobre qué significa «cliente activo». Conviene identificarlas al principio y hacerlas visibles, porque son las que paran el proyecto.

El criterio de terminado. Debe estar escrito antes de empezar. No es «el cuadro de mando está publicado», sino algo como: *el responsable de cada tienda consulta su cuadro al menos una vez por semana y las cifras coinciden con su cierre de caja.*

Iterar. La primera entrega debe ser pequeña, completa de punta a punta y útil: una sola área, tres o cuatro indicadores, una fuente. Es preferible un cuadro de mando de ventas funcionando en seis semanas que un almacén corporativo completo en dieciocho meses.

13.5. Los diez riesgos típicos

Riesgo	Cómo se manifiesta	Mitigación
Mala calidad del dato	Las cifras no cuadran con lo que sabe el negocio	Perfilar antes de planificar; validación en la carga
Definiciones divergentes de un KPI	Dos áreas llegan con dos cifras	Catálogo de indicadores con propietario
Fuentes incompatibles	Los cruces multiplican filas o pierden registros	Conformar dimensiones; declarar el grano
Datos incompletos	Períodos o entidades sin dato	Hacer visible la ausencia, nunca imputar en silencio
Sesgos de recogida	Sólo hay datos de una parte de la realidad	Documentar qué no se está midiendo
Falta de contexto	Cifras sin objetivo ni comparación	Ningún indicador sin referencia
Indicadores mal diseñados	Ratios agregados incorrectamente	Guardar numerador y denominador
Correlación tomada por causalidad	Se decide sobre una relación no verificada	Exigir experimento o declarar hipótesis
Automatizar una conclusión errónea	El error se repite cada noche	Revisión periódica de definiciones
Cuadro de mando que nadie usa	Uso nulo tras el entusiasmo inicial	Medir el uso; validar con usuarios reales

El último riesgo merece un comentario: **hay que medir el uso del cuadro de mando**. Es un dato que casi nadie recoge y que dice más sobre el éxito del proyecto que cualquier otro. Si el uso cae, hay que averiguar por qué antes de construir nada nuevo.

13.6. Evolución

Un sistema de BI no se entrega: se mantiene. Lo que hay que prever desde el principio:

- Qué pasa cuando una fuente cambia de estructura.
- Quién autoriza un indicador nuevo y con qué criterio.
- Cada cuánto se revisan las definiciones existentes.

- Cómo se retiran los indicadores que ya nadie usa.
- Cómo se gestiona el crecimiento del volumen.

Un catálogo de indicadores que sólo crece termina siendo inservible. Retirar indicadores es tan importante como añadirlos.

Ejercicios del capítulo 13

13.1. Escribe la pregunta de negocio inicial del proyecto de Rueda Libre en un formato que permita saber si el proyecto ha tenido éxito. Debe contener una decisión, un responsable y una forma de medirlo.

13.2. Elabora el inventario de fuentes de Rueda Libre indicando, para cada una: propietario probable, grano, riesgo de calidad principal y dependencia crítica.

13.3. Un proyecto planifica ocho semanas: una de análisis, una de datos, cinco de cuadros de mando y una de validación. Critica el reparto y propón otro.

13.4. Define el criterio de «terminado» para la primera entrega del proyecto de Rueda Libre. Debe ser verificable por alguien que no sea del equipo técnico.

13.5. Elige tres de los diez riesgos de la tabla y diseña, para cada uno, una comprobación automática que lo detecte antes de que llegue al comité de dirección.

Parte II · El caso Rueda Libre, paso a paso

Esta parte no explica conceptos nuevos. Reconstruye el proyecto en el orden en que ocurrió: qué se hizo, qué problema resolvía, qué se rompió y qué costó. Es la parte que da sentido a la primera.

14. Versión 1 — El informe mensual en hoja de cálculo

14.1. El punto de partida

Antes del proyecto, Rueda Libre tenía un informe. Lo hacía Gertru el primer lunes de cada mes y le llevaba dos días completos:

1. Exportar las ventas del TPV de cada una de las doce tiendas, una a una.
2. Exportar los pedidos de la tienda en línea.
3. Pegarlo todo en una hoja de cálculo.
4. Buscar y corregir a mano las familias de producto que no coincidían.
5. Cruzar con `Objetivos.xlsx` mediante búsquedas verticales.
6. Generar seis gráficos.
7. Enviarlos por correo a dirección y a los doce responsables de tienda.

14.2. Qué funcionaba

Conviene reconocerlo antes de criticarlo, porque explica por qué había durado tres años: el informe **respondía a una pregunta real** y Gertru conocía el negocio. Los ajustes manuales que hacía — descartar los traspasos entre tiendas, corregir las familias— eran conocimiento de negocio aplicado correctamente.

14.3. Qué no funcionaba

Dos días al mes de una persona. Veinticuatro días al año dedicados a copiar y pegar.

No era reproducible. El informe de marzo no se podía volver a generar en junio, porque el TPV sobrescribe los datos antiguos al cerrar el ejercicio.

El conocimiento estaba en una persona. Las reglas —qué se descarta, cómo se homogeneizan las familias— no estaban escritas en ninguna parte. Estaban en la cabeza de Gertru.

No permitía preguntar. El informe respondía siempre a las mismas seis preguntas. Cualquier pregunta nueva costaba otro día de trabajo.

Las cifras no cuadraban con las de finanzas. Nadie sabía por qué. Se descubrió en la versión 2: Gertru usaba la fecha del ticket y finanzas la fecha del cobro.

14.4. El diagnóstico

Aplicando el capítulo 13: el problema no era la herramienta. Una hoja de cálculo es perfectamente capaz de generar ese informe. El problema era que **la lógica de negocio estaba en un proceso manual y no**

documentado, y que **no había historia**.

La primera decisión del proyecto no fue comprar nada. Fue escribir, con Gertru, las quince reglas que ella aplicaba a mano.

Ese documento de quince reglas se convirtió en la especificación del proceso de carga, y es el entregable más valioso de toda la versión 1.

15. Versión 2 — Unificar las fuentes

15.1. El encargo

Que las cifras cuadren. Que haya una sola definición de venta. Que el informe se genere solo.

15.2. El inventario de fuentes

Primera tarea, y la que reveló el verdadero alcance:

Fuente	Grano	Historia	Riesgo principal
TPV (×12)	Línea de ticket	18 meses	Importes en céntimos; se purga al cerrar el año
Tienda en línea	Pedido	Completa	Catálogo propio; estados de pedido
Gestor de taller	Orden de reparación	Completa	Fechas nulas en órdenes abiertas
Fichero de clientes	Cliente	Completa	Duplicados masivos
ERP de compras	Albarán	5 años	Vuelca el coste con un mes de retraso
Objetivos.xlsx	Tienda y mes	3 años	Manual; se modifica después del cierre

Dos hallazgos que cambiaron la planificación:

El TPV purga los datos al cerrar el ejercicio. Sólo había 18 meses de historia disponible. La primera acción urgente del proyecto fue empezar a copiar el TPV a la capa de *staging* **antes** de tener nada más construido, para no perder más historia mientras se diseñaba el resto.

El grano del ERP no coincidía con el del TPV. El coste llegaba por albarán de proveedor, no por línea de venta. Calcular el margen por ticket exigía una regla de imputación de coste que nadie había definido nunca.

15.3. Las cuatro definiciones de venta

El problema que impedía que las cifras cuadraran. Se convocó una reunión con comercial, finanzas, tiendas y web, y se llegó a un acuerdo:

VENTA NETA (indicador oficial de la compañía)

Importe sin IVA

En la fecha del COBRO

Excluye traspasos entre tiendas

Excluye ventas a empleados

Las devoluciones restan en el mes de la devolución

Se conservaron además dos indicadores secundarios —*venta bruta* y *pedidos confirmados*— con nombres distintos, para que comercial y web pudieran seguir usando su cifra sin llamarla «ventas».

Ese acuerdo tardó tres semanas en cerrarse y fue la parte más difícil del proyecto entero. No tuvo ningún componente técnico.

15.4. La deduplicación de clientes

El fichero tenía 41.200 registros. Aplicando una regla de identidad basada en correo electrónico normalizado y teléfono normalizado, quedaron 28.700 clientes reales.

El efecto sobre los indicadores fue considerable:

	Antes	Después
Número de clientes	41.200	28.700
Venta media por cliente	84 €	121 €
Clientes recurrentes	12 %	31 %

El negocio no había cambiado. Lo único que había cambiado era que ahora se estaba midiendo bien. El porcentaje de clientes recurrentes, que la dirección consideraba un problema estratégico, resultó ser casi el triple de lo que se creía.

⚠ Este es el mejor ejemplo del capítulo 3 en todo el caso: **un problema de calidad del dato se había convertido en un diagnóstico erróneo de negocio**, y se habían tomado decisiones comerciales sobre él durante dos años.

15.5. Lo que se construyó

FUENTES → STAGING → INTEGRACIÓN → Informe automatizado

Sin modelo dimensional todavía. Una capa de integración con las reglas aplicadas y el mismo informe de siempre, generado automáticamente cada noche.

15.6. El balance de la V2

Se ganó: cifras que cuadran; dos días al mes liberados; reglas documentadas; historia que empieza a acumularse; el hallazgo de los clientes recurrentes.

Se pagó: nueve semanas de trabajo, seis de ellas en calidad de datos y definiciones. Cero en herramienta de visualización.

Quedó mal: el informe seguía respondiendo a seis preguntas fijas. Nadie podía preguntar nada nuevo. Y el margen seguía sin poder calcularse por ticket.

16. Versión 3 — El modelo dimensional

16.1. Por qué cambiar

La dirección hizo una pregunta que la V2 no podía responder: «¿qué familias de producto tiran del margen en las tiendas grandes y cuáles en las pequeñas?».

No era una limitación de la herramienta. Era que los datos estaban organizados como un informe y no como un modelo.

16.2. La decisión del grano

Se dedicó una sesión entera a completar la frase, y hubo discusión:

«Una fila de HECHO_VENTAS es una LÍNEA de ticket.»


La alternativa propuesta —una fila por ticket— habría reducido el volumen a la quinta parte y era tentadora. Se descartó porque impedía para siempre el análisis por producto, que era exactamente la pregunta que había originado la versión.

Para el taller:

«Una fila de HECHO_REPARACIONES es una orden de reparación,
esté cerrada o abierta, con su estado.»

La decisión de incluir las abiertas fue de Gertru, y evitó el sesgo de supervivencia: si sólo se cargaban las cerradas, el tiempo medio de reparación excluía sistemáticamente a las que más tardaban, que son las que siguen abiertas. El indicador habría estado permanentemente subestimado.

16.3. El modelo



Dimensiones conformadas: `DIM_FECHA` , `DIM_TIENDA` , `DIM_CLIENTE` y `DIM_PRODUCTO` son las mismas para los dos hechos. Eso es lo que permite preguntar «¿los clientes que usan el taller compran más?», que cruza los dos mundos.

`DIM_TIENDA` se implementó como dimensión de **tipo 2**, previendo la reorganización de regiones comerciales que efectivamente ocurrió seis meses después.

`DIM_FECHA` se generó a mano, con festivos por provincia y una columna `temporada` —alta de abril a septiembre, baja el resto— que resultó ser la variable más explicativa de todo el modelo.

16.4. La decisión sobre los ratios

Se estableció una regla de modelado que no se ha roto desde entonces:

En las tablas de hechos sólo se guardan **numeradores y denominadores**. Ningún porcentaje, ningún promedio, ningún ratio se almacena.

HECHO_VENTAS guarda:	<code>importe_neto · coste · unidades · num_tickets</code>
N0 guarda:	<code>margen_% · ticket_medio</code>

Margen porcentual y ticket medio se definieron como medidas calculadas en el modelo semántico. La consecuencia práctica es que salen bien a cualquier nivel de agregación y con cualquier filtro, automáticamente.

Fue esta decisión la que destapó el error del margen: el informe de la V2 daba un margen de cadena del 20 % promediando los porcentajes de las doce tiendas. El margen real era del 16,6 %.

⚠ Casi cuatro puntos de error en el indicador con el que se había fijado la política de precios del año anterior.

16.5. Lo que se rompió

La carga de reparaciones falló durante dos semanas sin que nadie se diera cuenta. Causa: Manolo teclea a mano el modelo de bicicleta cuando no lo encuentra en el desplegable, y una de sus entradas contenía un carácter que rompía el proceso de conformado. El proceso terminaba sin error y sin cargar la mitad de las órdenes.

De ahí salió la regla de validación de volumen: toda carga compara el número de registros con la media de las últimas cuatro ejecuciones y marca el resultado como incompleto si se desvía más de 2σ . Es el capítulo 5 aplicado a la operación.

17. Versión 4 — El cuadro de mando

17.1. Tres cuadros, no uno

La primera propuesta fue un único cuadro de mando para todos. Se descartó aplicando la pirámide del capítulo 1, y se construyeron tres:

Operativo • encargado de turno. Reparaciones pendientes, las que superan el plazo comprometido, stock por debajo del mínimo. Actualización continua, detalle al registro individual.

Táctico • responsable de tienda. Venta frente a objetivo, ticket medio con su distribución, margen por familia, tiempo de reparación con mediana y P90, comparación interanual. Actualización diaria, con navegación en profundidad hasta el ticket.

Estratégico • dirección. Seis indicadores: venta neta, margen, clientes recurrentes, ticket medio, satisfacción y tiempo de reparación. Cada uno con objetivo, interanual y distribución entre tiendas. Actualización mensual.

17.2. La tarjeta que cambió la conversación

El indicador de tiempo de reparación se publicaba como un solo número: 3,2 días de media. La dirección llevaba un año presionando al taller sin resultado.

Al publicarlo con dispersión:

Mediana	1,1 días	
P90	8,7 días	objetivo: < 7
Media	3,2 días	
3 % de las reparaciones supera los 3 días		

Quedó claro de inmediato que **no había un problema de tiempo típico**: nueve de cada diez clientes recogían su bicicleta al día siguiente. Había un problema de cola, concentrado en el 3 % de las órdenes: las restauraciones completas de Manolo.

Y ese 3 % no era un fallo de proceso: era una línea de negocio distinta, con un margen tres veces superior. La decisión que se tomó no fue apretar al taller, fue **separar el flujo**: dos circuitos, dos compromisos de plazo, dos indicadores.

Un año de presión sobre el taller se había basado en confundir la media con el colectivo. La solución no requirió ninguna tecnología: requirió publicar tres cifras en lugar de una.

17.3. La auditoría del cuadro de mando

Antes de publicar se pasó el cuadro por una revisión sistemática. Lo que se encontró:

Problema encontrado	Corrección
Margen de cadena como media de porcentajes	Recalcular desde totales
Gráfico de ventas con eje empezando en 130.000	Eje desde cero
«Satisfacción media 4,3» sin distribución	Añadir % de valoraciones 1 y 2
Ranking de tiendas por conversión sin volumen	Añadir tamaño de muestra; ocultar bajo 30 casos
Comparación con el mes anterior en un negocio estacional	Sustituir por interanual
Sectores con nueve familias de producto	Barras horizontales ordenadas
Diez indicadores sin objetivo	Definir objetivo o retirar

Siete correcciones. Ninguna era un fallo técnico: todas eran errores conceptuales sobre un cuadro que funcionaba perfectamente.

18. Versión 5 — Del descriptivo al predictivo

18.1. Por qué ahora

Sólo cuando el descriptivo era fiable —dos años de historia limpia, definiciones acordadas, modelo estable— tuvo sentido subir el siguiente escalón de la escalera del capítulo 1.

18.2. La descomposición de la serie

Antes de predecir nada, se descompuso la serie de ventas:

Tendencia	+4,1 % anual
Estacionalidad	Abril–septiembre concentra el 68 % de la venta Sábado es el mejor día (2,3× la media semanal)
Ciclo	No identificable con dos años de historia
Ruido	±7 % mensual

El último dato fue el más útil de los cuatro y no requirió ningún modelo: **la serie oscila habitualmente un ±7 %**. Eso significa que las reuniones de urgencia por caídas del 5 % llevaban dos años convocándose por ruido.

18.3. El pronóstico

Se construyeron tres modelos y se compararon todos contra el ingenuo estacional:

Modelo	Error medio
Ingenuo (mes anterior)	31 %
Ingenuo estacional (mismo mes año anterior)	9,4 %
Media móvil de 12 meses	14 %
Suavizado exponencial con estacionalidad	6,8 %

El suavizado exponencial ganó, pero por poco margen sobre el ingenuo estacional. La conclusión que se llevó a dirección fue honesta: *el modelo sofisticado aporta 2,6 puntos de precisión sobre mirar el mismo mes del año pasado*. Con esa información, la dirección decidió adoptarlo igualmente, pero sabiendo lo que compraba.

La presentación del pronóstico se hizo siempre con los tres elementos:

Julio: 148.000 € · intervalo 131.000 – 165.000 (80 %)

Supuestos: sin aperturas · sin cambios de precio · meteorología normal

18.4. La segmentación de clientes

Se aplicó agrupamiento sobre la base de clientes. La empresa segmentaba por importe de compra — bronce, plata, oro—. El algoritmo encontró cuatro grupos distintos:

Ciclista de competición	Alto gasto, alta frecuencia, alto uso de taller, estacional
Urbano de trayecto	Gasto medio, muy recurrente, poco estacional
Comprador de regalo	Compra única, alto importe, diciembre y junio
Aficionado de fin de semana	Gasto medio-bajo, estacional extremo

El grupo urbano de trayecto era el más rentable a tres años y el que la segmentación anterior no distinguía en absoluto: quedaba repartido entre bronce y plata. Sobre ese hallazgo se construyó la campaña del año siguiente.

18.5. El límite

Se planteó automatizar el pedido de stock a partir del pronóstico. Se descartó, por el riesgo de realimentación del capítulo 12: si el pronóstico determina el pedido y el pedido determina la venta — porque no se puede vender lo que no está en la tienda—, el modelo acabaría prediciendo su propia decisión.

La solución fue mantener el pronóstico como **propuesta** revisada por el responsable de compras, y medir aparte la demanda perdida por rotura de stock.

19. Balance de la evolución

19.1. Lo que costó cada salto

Versión	Duración	Esfuerzo principal
V2 · Unificar fuentes	9 semanas	6 en calidad de datos y definiciones
V3 · Modelo dimensional	6 semanas	2 sólo en decidir el grano
V4 · Cuadros de mando	4 semanas	1 en la auditoría previa a publicar
V5 · Predictivo	5 semanas	3 en validar que el descriptivo aguantaba

Veinticuatro semanas en total. **De ellas, catorce se dedicaron a datos y definiciones, y cuatro a construir cuadros de mando.** Es el reparto normal, y es el que casi ninguna planificación inicial contempla.

19.2. Lo que se reutilizó

Cada versión se apoyó en la anterior sin rehacerla:

- Las quince reglas escritas con Gertru en la V1 siguen siendo la especificación del proceso de carga.
- La capa de *staging* de la V2 permitió reconstruir todo el histórico cuando en la V3 cambió la regla de imputación de coste. Sin ella habrían sido dos años perdidos.
- Las dimensiones conformadas de la V3 permitieron añadir el hecho de reparaciones sin tocar nada de ventas.
- El modelo semántico con ratios calculados hizo que los tres cuadros de la V4 dieran las mismas cifras sin ningún esfuerzo adicional.

19.3. Lo que no está bien

Un balance honesto incluye lo que quedó pendiente:

El coste sigue imputándose por una regla aproximada. El ERP no da coste por línea de venta y la regla de reparto por albarán es una estimación. El margen por producto individual es orientativo, y así está marcado en el cuadro de mando.

Objetivos.xlsx sigue siendo un fichero manual. Se añadió una validación que detecta modificaciones posteriores al cierre, pero la fuente sigue dependiendo de una persona.

No hay medición de la demanda perdida. No se sabe cuántas ventas se pierden por rotura de stock, lo que sesga a la baja todos los análisis de demanda.

El uso del cuadro de mando operativo es bajo. Cuatro de las doce tiendas apenas lo abren. Está pendiente averiguar si es un problema de diseño, de formación o de que resuelve algo que no era un problema.

19.4. Las cinco lecciones

1. **El proyecto no empezó cuando se compró la herramienta.** Empezó cuando se escribieron las reglas que Gertru aplicaba a mano.
2. **El hallazgo más valioso fue de calidad de datos, no de análisis.** Los clientes recurrentes eran el triple de lo que se creía porque el fichero tenía duplicados. Ninguna técnica avanzada habría encontrado eso.
3. **El error más caro fue conceptual, no técnico.** Promediar porcentajes de margen desvió la política de precios de un año entero, sobre un sistema que funcionaba perfectamente.
4. **Publicar la dispersión cambió una decisión de negocio.** Un año de presión sobre el taller se resolvió sustituyendo un número por tres.
5. **Lo más difícil no tuvo componente técnico.** Fueron las tres semanas de reuniones hasta acordar qué significa «venta».

Business Intelligence no consiste en hacer gráficos. Consiste en transformar datos en evidencia para tomar decisiones. Todo lo demás es infraestructura.

Ejercicios de la Parte II

- II.1.** La V2 descubrió que había 28.700 clientes reales y no 41.200. Enumera tres indicadores del cuadro de mando anterior que estaban mal y explica en qué dirección se equivocaban.
- II.2.** Se decidió cargar las reparaciones abiertas además de las cerradas. Explica con un ejemplo numérico cómo habría quedado sesgado el tiempo medio si sólo se hubieran cargado las cerradas.
- II.3.** El suavizado exponencial mejora el error del 9,4 % al 6,8 % frente al ingenuo estacional. Escribe el argumento que llevarías a dirección a favor de adoptarlo, y el que llevarías en contra. ¿Cuál defiendes?
- II.4.** Diseña la validación automática que habría detectado el fallo de carga de reparaciones provocado por la entrada manual de Manolo.
- II.5.** Cuatro de las doce tiendas no usan el cuadro de mando operativo. Diseña el plan para averiguar por qué, con al menos tres fuentes de información distintas.
- II.6.** Toma la lección 3 —el error del margen promediado— y escribe el correo de dos párrafos que enviarías a dirección explicando qué pasó, sin culpar a nadie y sin minimizar el impacto.
-

Apéndices

Apéndice A · El temario oficial, punto por punto

Este apéndice relaciona cada punto del programa formativo oficial **ADGG102PO · Business Intelligence** con el capítulo de este manual donde se estudia y con el punto del caso Rueda Libre que lo ilustra. Sirve para dos cosas: comprobar la cobertura del temario y localizar rápidamente el ejemplo de cualquier concepto.

Bloque 1 · Inteligencia de negocios

Punto del temario	Capítulo	Dónde se ve en el caso
1.1 · Introducción	1.1 – 1.3	Las cinco mil nóminas · El informe manual de la V1
1.2 · La pirámide organizacional	1.4	Los tres cuadros de mando de la V4 (17.1)
1.3 · Herramientas de inteligencia de negocios	1.6, 11.6	Familias de herramientas; decisión deliberada de no empezar por ahí
1.4 · Fundamentos del Datawarehouse	6.3	La capa de integración de la V2
1.5 · Características	6.3	Las cuatro propiedades de Inmon aplicadas a Rueda Libre
1.6 · Ventajas	6.3	Cifras que cuadran; historia que el TPV purgaba
1.7 · Sistemas OLTP	6.1, 6.2	TPV, gestor de taller, ERP y sus límites
1.8 · Implementación del Datawarehouse	6.5, 6.6, 8	Capas, <i>staging</i> e historificación de DIM_TIENDA
1.9 · Análisis OLAP: Drill Down, Drill Up	8.8	Navegación región → tienda en el cuadro táctico
1.10 · Servidores OLAP: ROLAP, MOLAP, HOLAP	8.9	Tratamiento histórico y qué sobrevive hoy
1.10 · Minería de datos, definiciones de Data Mining	10.1	Qué es y qué no es
1.11 · Categorías de Data Mining	10.2	Las seis categorías con su caso de negocio
1.12 · Proceso de Minería de Datos	10.3	Las seis fases
1.13 · Metodología	10.4, 13.2	CRISP-DM y las once fases del proyecto
1.14 · Reportes	11.6	El informe mensual de la V1 y su automatización
1.15 · Consultas	11.6	Autoservicio gobernado sobre el modelo semántico
1.16 · Alertas	11.6	Umbral estadístico de la validación de carga (16.5)
1.17 · Análisis	5, 9	Análisis exploratorio, segmentación y correlación
1.18 · Pronósticos	12	Los cuatro modelos comparados de la V5 (18.3)

Bloque 2 · La gestión de proyectos de Business Intelligence

Punto del temario	Capítulo	Dónde se ve en el caso
2.1 · Gestión de proyectos	13.1 – 13.3	Por qué no es un proyecto de desarrollo
2.2 · Planificación del proyecto	13.4	El reparto real de las 24 semanas (19.1)
2.3 · Riesgos	13.5	Los diez riesgos · El error del margen (16.4)

Bloque 3 · Arquitectura de un proyecto de Business Intelligence

Punto del temario	Capítulo	Dónde se ve en el caso
3.1 · Procesos de Extracción, Transformación y Carga	7.1 – 7.3	Las quince reglas de Gertru convertidas en proceso
3.2 · El almacén de datos	6.3 – 6.5	Las capas de la V2
3.3 · Visualización y consulta: Reportes	11.6	Informes operativos y analíticos
3.4 · Visualización y consulta: Dashboards	11.7, 11.8	Los tres cuadros y su auditoría (17.3)
3.5 · Visualización y consulta: OLAP	8.8	Las cinco operaciones sobre el modelo
3.6 · Visualización y consulta: Data Mining	10	La segmentación de clientes de la V5 (18.4)
3.7 · Procesos ETL	7.4, 7.5	ETL frente a ELT; orquestación y fallos
3.8 · Creación de cubos multidimensionales	8.1 – 8.8	El modelo dimensional de la V3

Contenidos añadidos que no están en el temario oficial

Se incluyen porque, sin ellos, buena parte del temario oficial se aplica mal:

Contenido	Capítulo	Por qué se añade
Escalas de medida	2	Determina qué es dimensión, qué es hecho y qué técnica se puede aplicar
Calidad del dato	3	Es el 25 % del esfuerzo real de cualquier proyecto
Dispersión y posición	5	Sin ella, cualquier KPI de tendencia central es engañoso
Aditividad y media ponderada	8.6 – 8.7	Es el error más frecuente en cuadros de mando reales
Correlación y causalidad	9.5 – 9.6	El puente entre «análisis» y «decisión» del punto 1.17
Definición operativa de KPI	11.2	Lo que hace que los puntos 1.14 a 1.16 sean fiables

Apéndice B • Glosario de términos

Aditiva (métrica). Métrica que puede sumarse a lo largo de todas las dimensiones. El importe de venta lo es; el stock y los porcentajes, no.

Agrupamiento (*clustering*). Técnica de minería de datos que descubre grupos naturales en un conjunto sin conocerlos de antemano. Aprendizaje no supervisado.

Almacén de datos (*Data Warehouse*). Repositorio integrado, temático, no volátil e histórico donde se consolidan los datos de todas las fuentes para su análisis.

Asimetría. Falta de simetría de una distribución. Positiva si la cola se extiende hacia la derecha (media > mediana), negativa en el caso contrario.

Atípico (*outlier*). Observación que se aleja marcadamente del resto. Criterio habitual: fuera de $Q1 - 1,5 \cdot IQR$ o $Q3 + 1,5 \cdot IQR$.

Captura de cambios (*CDC*). Técnica de extracción que lee las modificaciones directamente del registro de transacciones del sistema de origen.

Chebyshev (desigualdad de). Garantiza que, sea cual sea la distribución, al menos $1 - 1/k^2$ de los individuos están a menos de k desviaciones típicas de la media. Para $k = 2$, al menos el 75 %. Para $k = 1$ no garantiza nada.

Conformado (de dimensiones). Proceso de unificar los códigos y descripciones de las distintas fuentes en un catálogo común, de modo que la misma entidad se identifique igual en todo el almacén.

Correlación. Medida del grado en que dos variables cuantitativas varían conjuntamente, entre -1 y $+1$. No implica causalidad.

CRISP-DM. Metodología estándar de proyectos de minería de datos, en seis fases cíclicas que empiezan por la comprensión del negocio.

Cuartil. Cada uno de los tres valores que dividen un conjunto ordenado en cuatro partes iguales. Q2 es la mediana.

Cubo multidimensional. Estructura que organiza los hechos según las dimensiones, con las agregaciones precalculadas por nivel de jerarquía.

Datamart. Subconjunto del almacén orientado a un área concreta de negocio.

Desviación típica (σ). Raíz cuadrada de la varianza. Mide la dispersión en las mismas unidades que la variable.

Dimensión. Tabla que aporta el contexto descriptivo de los hechos: quién, qué, dónde, cuándo. Sus atributos son variables nominales u ordinales.

Dimensión lentamente cambiante (SCD). Estrategia para tratar los cambios en los atributos de una dimensión. Tipo 1 sobrescribe, tipo 2 versiona con fechas de validez, tipo 3 conserva el valor anterior en otra columna.

Drill-down / drill-up. Operaciones de navegación que bajan o suben un nivel en una jerarquía.

ELT. Variante del ETL en la que se carga el dato en bruto y la transformación se ejecuta dentro del propio almacén.

ETL. Extracción, transformación y carga. El conjunto de procesos que lleva el dato desde las fuentes hasta el almacén.

Frecuencia absoluta. Número de individuos que comparten un mismo valor.

Frecuencia acumulada. Suma de las frecuencias hasta un valor dado. Sólo tiene sentido en escalas ordinales o superiores.

Frecuencia relativa. Proporción de individuos con un valor dado sobre el total.

Fuga de información (data leakage). Error por el que una variable de entrada de un modelo contiene, directa o indirectamente, la respuesta que se quiere predecir.

Granularidad (grano). Lo que representa una fila de una tabla de hechos. La decisión más importante de un modelo dimensional.

Hecho. Tabla que registra los eventos medibles del negocio. Contiene métricas cuantitativas y claves hacia las dimensiones.

Histograma. Gráfico de la distribución de una variable continua, con el eje horizontal graduado y el área proporcional a la frecuencia.

HOLAP. Implementación híbrida de OLAP: agregados en estructura multidimensional y detalle en base relacional.

Interanual. Comparación con el mismo período del año anterior. Elimina el efecto de la estacionalidad.

IQR (rango intercuartílico). $Q3 - Q1$. Amplitud del intervalo que contiene al 50 % central de los individuos. Es la medida de dispersión asociada a la mediana.

KPI. Indicador que mide el avance hacia un objetivo y cuyo valor cambia una decisión. Una métrica que no cambia ninguna decisión no es un KPI.

Media. Suma de todos los valores dividida entre el número de individuos. Sólo tiene sentido en escalas cuantitativas. Indicador suficiente pero no robusto.

Media ponderada. Media en la que cada valor se pondera por su peso relativo. Es la forma correcta de agregar ratios cuando no se dispone de los totales.

Mediana. Valor que ocupa el centro del conjunto ordenado. Deja el 50 % por debajo. Indicador robusto pero no suficiente.

Moda. Valor más frecuente. Único indicador de tendencia central disponible para variables nominales.

MOLAP. Implementación de OLAP sobre una estructura multidimensional propia con las agregaciones precalculadas.

Multimodal. Distribución con varios picos. Suele indicar que hay dos o más poblaciones distintas mezcladas.

Nominal (escala). Escala de medida que sólo permite clasificar. No hay orden.

No aditiva (métrica). Métrica que no puede sumarse por ninguna dimensión. Todos los ratios, porcentajes y promedios lo son.

OLAP. *On-Line Analytical Processing.* Sistemas diseñados para consultas analíticas sobre grandes volúmenes.

OLTP. *On-Line Transaction Processing.* Sistemas diseñados para registrar transacciones operativas.

Ordinal (escala). Escala de medida que permite clasificar y ordenar, pero sin unidad de medida. Admite mediana y percentiles; no admite media.

Paradoja de Simpson. Fenómeno por el que una relación observada en los datos agregados se invierte o desaparece al analizar los subgrupos.

Percentil. Valor que deja por debajo un porcentaje dado de los individuos. P90 deja por debajo al 90 %.

Puntuación diferencial. Diferencia entre el valor de un individuo y la media del conjunto. Su promedio es siempre cero.

Ratio. Cociente entre dos magnitudes. No se agrega: se recalcula desde los totales.

Razón (escala de). Escala cuantitativa con cero absoluto que indica ausencia de la propiedad. Admite multiplicación y división.

Regla empírica. Si la distribución es aproximadamente normal, el 68 % de los casos está a $\pm 1\sigma$ de la media, el 95 % a $\pm 2\sigma$ y el 99,7 % a $\pm 3\sigma$.

Robusto (indicador). Indicador insensible a los valores extremos. La mediana lo es; la media no.

ROLAP. Implementación de OLAP que traduce las consultas a SQL sobre un modelo relacional en estrella.

Semiaditiva (métrica). Métrica que puede sumarse por unas dimensiones y no por otras. El stock se suma entre tiendas y no entre días.

Sesgo de supervivencia. Error de análisis por trabajar sólo con los casos que han llegado al final, ignorando los que no. Cargar sólo las reparaciones cerradas lo produce.

Sobreajuste (*overfitting*). Situación en que un modelo aprende de memoria los datos de entrenamiento y falla sobre datos nuevos.

Staging. Capa donde se deposita el dato en bruto tal como llega, antes de transformarlo. Permite reprocesar sin volver a la fuente.

Suficiente (indicador). Indicador que utiliza toda la información del conjunto para su cálculo. La media lo es; la mediana no.

Varianza. Media de los cuadrados de las desviaciones respecto a la media. Sus unidades son las de la variable al cuadrado, lo que la hace difícil de interpretar.

Apéndice C · Referencia rápida de indicadores

C.1. Qué se puede calcular con cada escala

Indicador	Nominal	Ordinal	Cuantitativa
Frecuencias absoluta y relativa	✓	✓	✓
Frecuencia acumulada	✗	✓	✓
Moda	✓	✓	✓
Mediana	✗	✓	✓
Cuartiles y percentiles	✗	✓	✓
Rango intercuartílico	✗	✓	✓
Media	✗	✗	✓
Varianza y desviación típica	✗	✗	✓
Correlación	✗	Con reservas	✓

C.2. Cómo se interpreta cada indicador

Indicador	Qué dice	Cómo se enuncia
Moda	El valor más frecuente	«Lo más habitual es...»
Mediana	El centro del colectivo	«La mitad está por debajo de...»
Media	Lo que tocaría a cada uno si todos aportaran igual	«Si repartiéramos por igual...»
Desviación típica	Dispersión en torno a la media	«Al menos el 75 % está entre media $\pm 2\sigma$ »
IQR	Amplitud del 50 % central	«La mitad central está entre Q1 y Q3»
P90	El valor que sólo supera el 10 %	«9 de cada 10 están por debajo de...»
Correlación	Grado de variación conjunta	«Cuando sube A, tiende a subir B»

C.3. Qué indicador usar según la forma

Forma de la distribución	Tendencia central	Dispersión
Simétrica	Media	Desviación típica
Asimétrica	Mediana	Rango intercuartílico
Multimodal	Ninguno: segmentar primero	—
Con atípicos que son reales	Mediana, y analizar los atípicos aparte	IQR + recuento de atípicos
Con atípicos que son errores	Corregir el dato y volver a empezar	—

C.4. Reglas de interpretación de la dispersión

SIEMPRE CIERTO (Chebyshev)

$\text{media} \pm 2\sigma$ contiene al menos el 75 % de los individuos

$\text{media} \pm 3\sigma$ contiene al menos el 89 %

$\text{media} \pm 1\sigma$ no garantiza nada

SÓLO SI LA DISTRIBUCIÓN ES APROXIMADAMENTE NORMAL (regla empírica)

$\text{media} \pm 1\sigma$ contiene ≈ 68 %

$\text{media} \pm 2\sigma$ contiene ≈ 95 %

$\text{media} \pm 3\sigma$ contiene $\approx 99,7$ %

ATÍPICOS

fuera de $Q1 - 1,5 \cdot IQR$ o $Q3 + 1,5 \cdot IQR$ → atípico

fuera de $Q1 - 3 \cdot IQR$ o $Q3 + 3 \cdot IQR$ → atípico extremo

C.5. Agregación de métricas

Tipo	Se suma por	Ejemplo	Cómo se agrega
Aditiva	Todas las dimensiones	Importe, unidades, coste	Suma
Semiaditiva	Todas menos el tiempo	Stock, saldo, plantilla	Suma entre entidades; último valor o media en el tiempo
No aditiva	Ninguna	Margen %, ticket medio, conversión	Recalcular desde los totales

NUNCA	media de los porcentajes de cada tienda	
SIEMPRE	$\Sigma \text{ numerador} / \Sigma \text{ denominador}$	
ALTERNATIVA	$\Sigma (\text{valor}_i \times \text{peso}_i) / \Sigma \text{ peso}_i$	(media ponderada)

C.6. Elección de gráfico

Objetivo	Gráfico	Evitar
Comparar categorías	Barras	Sectores con más de 5
Composición	Barras apiladas al 100 %	Sectores en 3D
Evolución temporal	Líneas	Barras si hay muchos puntos
Distribución	Histograma, caja y bigotes	Sólo la media
Comparar distribuciones	Cajas múltiples, violines	Medias en una tabla
Relación entre variables	Dispersión	Sólo el coeficiente
Valor contra objetivo	Barra con marcador	Semáforo sin la cifra

C.7. Comparaciones temporales

Comparación	Qué responde	Cuándo usarla
Frente al período anterior	Movimiento inmediato	Series sin estacionalidad
Interanual	Crecimiento real	Siempre en negocios estacionales
Acumulado del año	Avance hacia el objetivo anual	Seguimiento de objetivos
Media móvil de 12	Tendencia limpia	Detectar cambios de fondo
Frente a objetivo	Cumplimiento	Rendición de cuentas

C.8. Lista de comprobación antes de publicar un indicador

- ☐ ¿Está escrita su definición operativa completa?
 - ☐ ¿Tiene un propietario?
 - ☐ ¿Qué decisión cambia según su valor?
 - ☐ Si es un ratio, ¿se recalcula desde los totales?
 - ☐ ¿Lleva su indicador de dispersión?
 - ☐ ¿Lleva contexto: objetivo, interanual o distribución?
 - ☐ ¿Se muestra el tamaño de la muestra?
 - ☐ ¿El eje del gráfico empieza donde debe?
 - ☐ ¿Se puede hacer drill-down para ver los segmentos?
 - ☐ ¿Alguien del negocio ha validado que reconoce la cifra?
-

Apéndice D · Soluciones de los ejercicios

Capítulo 1 · Qué es Business Intelligence

1.1. Hay al menos cinco preguntas distintas: ¿vende más en importe o en unidades? ¿En qué familias? ¿Es una diferencia de número de tickets o de ticket medio? ¿Es estable en el tiempo o de un período concreto? ¿Y «del mismo tamaño» significa superficie, plantilla o mercado potencial? Sin desdoblarla, cualquier respuesta será parcial. Se retoma en 9.3.

1.2. (a) Operativo, grano de orden individual, actualización continua. (b) Táctico, grano de familia y trimestre. (c) Estratégico, muy agregado, con serie larga. Cada uno necesita un almacén con detalle suficiente: por eso el grano se elige al máximo detalle, no al nivel del informe.

1.3. No se puede subir al escalón predictivo sin tener resuelto el descriptivo. La recomendación es dedicar el presupuesto a unificar la definición de venta, y sólo después plantear el modelo. Un modelo entrenado sobre dos cifras contradictorias producirá predicciones precisas de un número que no significa nada.

1.4. Respuesta abierta. El resultado habitual es que se responden dos o tres de las nueve, y las que más cuesta responder son la 2 (de dónde viene) y la 5 (si la media es representativa).

Capítulo 2 · Escalas de medida

2.1. `id_ticket` nominal (identificador, dimensión degenerada); `fecha` cuantitativa de intervalo, dimensión; `id_tienda` nominal, dimensión; `código_postal_cliente` nominal aunque sea numérico, dimensión; `forma_de_pago` nominal, dimensión; `unidades` cuantitativa discreta de razón, hecho; `importe` cuantitativa continua de razón, hecho; `descuento_%` es un ratio: se guarda el importe de descuento como hecho y el porcentaje se calcula; `valoración_1_a_5` ordinal, dimensión, y no se promedia.

2.2. El código postal no es una cantidad: no tiene unidad de medida y su media no señala ningún lugar. La necesidad real es saber dónde se concentran los clientes. Dos respuestas correctas: la moda —el código postal más frecuente— o un mapa con la frecuencia por área, que además muestra la dispersión.

2.3. Para el jefe de taller, intervalos finos en la parte baja (0–2 h, 2–4 h, 4–8 h, 8–24 h, más de 24 h): sus decisiones son de asignación diaria. Para dirección, intervalos ligados al compromiso de servicio (dentro de plazo, hasta 2 días de retraso, más de 2 días). No son la misma porque responden a decisiones distintas: la agrupación es una decisión de análisis.

2.4. «¿Cuál es la distribución completa de las valoraciones y cuántas respuestas hay?» Un 7,2 puede venir de todo el mundo puntuando 7 o de la mitad puntuando 4 y la otra mitad 10. Se publicaría junto a la mediana y al porcentaje de valoraciones de 5 o menos.

2.5. La temperatura en grados Celsius es una escala de intervalo: su cero es arbitrario. La afirmación correcta es «en julio la temperatura media fue 20 grados superior a la de enero». Para hablar de proporciones habría que usar una escala de razón como el kelvin, donde la diferencia sería del 7 %.

Capítulo 3 · La calidad del dato

3.1. Afecta a la **validez**. Causas posibles: fechas invertidas al teclear; órdenes reabiertas conservando la fecha de salida antigua; zona horaria distinta en entrada y salida. Con la primera se corrige intercambiando; con la segunda hay que definir qué es «la salida»; con la tercera se normaliza en la carga. En ningún caso se descartan sin registrar cuántos eran.

3.2. Tres valores posibles: (a) excluyendo los tickets sin cliente, sube porque se divide entre menos; (b) tratando los nulos como un cliente ficticio único, baja mucho; (c) tratando cada ticket sin cliente como un cliente distinto, baja también. Se publicaría (a), indicando expresamente que se calcula sobre el 82 % de los tickets identificados.

3.3. Estuvieron mal todos los indicadores absolutos que mezclaban ambos canales —venta total, ticket medio global, margen— y todos los ratios cuyo numerador o denominador cruzaba canales. Se salvaron los indicadores calculados **dentro** de un solo canal, porque el factor cien afectaba a numerador y denominador por igual, y los de unidades, que no llevan importe.

3.4. (a) Rango: ningún importe unitario fuera de $[0, 20.000]$ €. (b) Coherencia: fecha de salida $\geq$ fecha de entrada. (c) Volumen: número de registros dentro de media $\pm 2\sigma$ de las últimas ejecuciones. Una cuarta útil: total por canal comparado con el del día anterior, para detectar cambios de unidad.

3.5. Afecta a **puntualidad** y a **no volatilidad**. Solución: congelar el fichero en la carga —guardar una copia sellada con fecha en *staging*— y comparar en cada ejecución con la versión anterior, avisando de las modificaciones retroactivas.

Capítulo 4 · Frecuencias y tendencia central

4.1. Más de 24 horas: $8\% + 3\% = 11\%$. Entre 5 y 24 horas: $310 + 160 = 470$. La mediana está en el intervalo 5–8 horas, que es el primero cuya acumulada (73 %) alcanza el 50 %.

4.2. «Familia igual o inferior a bicicleta» no significa nada: la familia de producto es nominal y no tiene orden. El 90,4 % de la tabla ordenada por frecuencia sólo permite decir que «tres familias concentran el 90 % de las operaciones».

4.3. La distribución es bimodal: hay dos poblaciones mezcladas, la venta de accesorios y la de bicicletas completas. Antes de calcular ningún indicador global hay que segmentar y analizarlas por separado, porque ninguna media describirá a ninguna de las dos.

4.4. Media = 292,3; mediana = 57,5. Se publica la mediana: la media está determinada por un solo valor. El 2.400 no se elimina; se comprueba si es real —una venta de bicicleta completa— y en ese caso se analiza en el segmento que le corresponde.

4.5. «El gasto habitual de nuestros clientes está en torno a 54 €. La media, de 128 €, refleja el peso de las ventas de bicicleta completa, que son pocas pero de importe muy alto.» Dos frases, las dos ciertas, ninguna engañosa.

4.6. Porque codificar como 1, 2 y 3 no crea una unidad de medida: sigue sin haber garantía de que la distancia entre «baja» y «normal» sea la misma que entre «normal» y «urgente». Se usa la mediana, y se publica la distribución de frecuencias.

Capítulo 5 · Dispersión, posición y forma

5.1. Valencia tiene un negocio heterogéneo —mezcla ventas pequeñas y grandes— y Zaragoza uno muy homogéneo. En Valencia tiene sentido segmentar y trabajar los tickets altos; en Zaragoza, buscar crecer el ticket típico. El mismo objetivo comercial produciría acciones distintas.

5.2. Con Chebyshev: «al menos el 75 % de los tickets está entre 38 € y 218 €». Con normalidad: «aproximadamente el 68 % está entre 83 € y 173 €». Se publicaría la primera, porque no exige suponer nada sobre la distribución y en un ticket de venta —claramente asimétrico— la suposición de normalidad no se sostiene.

5.3. Ordenados, $n = 12$. Mediana = $(1,5 + 2)/2 = 1,75$. $Q1 = 1$, $Q3 = 3,5$, $IQR = 2,5$. Límite superior = $3,5 + 1,5 \times 2,5 = 7,25$. El valor 21 es atípico; supera también $3,5 + 3 \times 2,5 = 11$, luego es atípico extremo. No se elimina: es una restauración de Manolo, un caso real de otra línea de negocio.

5.4. A favor: el indicador global sería más estable y representaría mejor a la reparación estándar. En contra: se estaría ocultando el 3 % de casos que genera la mayor parte de las quejas y el mayor margen. Decisión correcta: no eliminar, **segmentar** en dos flujos con dos compromisos de plazo distintos.

5.5. Un histograma con un pico pronunciado hacia 35 €, descendiendo deprisa, y una cola larga hacia la derecha. Es asimetría positiva. Se publica la mediana como tendencia central, acompañada del P90 para no perder la cola.

5.6. Porque el diagrama de caja sólo usa cinco números: dos distribuciones con los mismos cuartiles pueden tener una sola concentración central o dos grupos separados. Se distinguen con un histograma o con un gráfico de violín.

5.7. Porque un solo número no puede describir a la vez el caso típico y la cola, y las decisiones sobre el taller dependen de las dos cosas. Se propone: mediana (1,1 d), P90 (8,7 d) y porcentaje que supera el compromiso de plazo.

Capítulo 6 · Sistemas operacionales y analíticos

6.1. Necesita una dimensión de **tipo 2**, para que las ventas de cada año queden asociadas a la región vigente en su momento. Si lo que quiere es analizar la evolución con la estructura actual, necesita además el atributo de región actual en la misma dimensión: son dos análisis distintos y ambos legítimos.

6.2. (1) Rendimiento: las consultas analíticas bloquean el cobro en caja. (2) No hay historia: el TPV purga al cerrar el ejercicio. (3) No hay integración: faltan la web, el taller y el ERP. (4) No hay historificación: los cambios de catálogo reescriben el pasado y los informes antiguos dejan de ser reproducibles.

6.3. Integrado: unificar las cuatro definiciones de venta. Temático: organizar por ventas, taller y clientes, no por TPV, web y ERP. No volátil: que el informe de marzo se pueda regenerar en junio. Histórico: que las ventas de 2023 sigan perteneciendo a la región Levante.

6.4. Los dos datamarts darían cifras distintas de «número de clientes» y ninguna sería comparable. Se resuelve conformando la dimensión cliente: una única `DIM_CLIENTE` con un atributo que distinga el rol, de modo que cada área filtre lo que necesite sobre el mismo maestro.

6.5. Porque permite reprocesar todo el histórico si cambia una regla de transformación. En el caso Rueda Libre salvó el proyecto cuando en la V3 cambió la regla de imputación de coste: sin *staging* habrían sido dos años de historia perdidos.

Capítulo 7 · Procesos ETL

7.1. Con carga incremental por fecha de modificación, si el TPV sella los registros con la fecha original, las ventas de los tres días no se habrían cargado nunca. Con carga completa se habrían recuperado solas. Lo detecta un control de volumen por tienda y día comparado con su media histórica.

7.2. Opción A: la devolución resta del mes de la venta original. Opción B: resta del mes de la devolución. Con A, las cifras publicadas de meses cerrados cambian retroactivamente; con B, no. Se elige B por no volatilidad, y se publica aparte un indicador de tasa de devolución por mes de venta.

7.3. (1) Descartar la línea: los totales dejan de cuadrar y nadie sabe por qué. (2) Asignarla a un miembro «desconocido» de la dimensión: los totales cuadran y el problema es visible. (3) Crear el artículo al vuelo con los datos disponibles: cuadra, pero contamina el catálogo. Se recomienda (2).

7.4. Primero las dimensiones sin dependencias: `DIM_FECHA` , `DIM_TIENDA` , `DIM_PRODUCTO` , `DIM_CLIENTE` , `DIM_EMPLEADO` . Después los hechos: `HECHO_VENTAS` y `HECHO_REPARACIONES` . Un hecho cargado antes que su dimensión genera huérfanos.

7.5. (1) ¿Qué decisión concreta se va a tomar con un dato de hace cinco minutos que no se pueda tomar con el de anoche? (2) ¿Está la fuente preparada para extracciones continuas sin afectar a la operación? (3) ¿Quién asume el coste de infraestructura y de mantenimiento que multiplica? Casi siempre, la respuesta a la primera hace innecesarias las otras dos.

Capítulo 8 · El modelo dimensional

8.1. Una orden de reparación, abierta o cerrada, con su estado. Con un grano más grueso —por tienda y mes— se perdería la posibilidad de calcular percentiles del tiempo de reparación, que es exactamente el análisis que resolvió el problema del taller en la V4.

8.2. Aditivas: unidades, importe neto, coste de las piezas. Semiaditiva: stock a fin de día. No aditivas: margen %, ticket medio, tiempo medio de reparación. El número de clientes distintos es un caso particular: es no aditivo porque un mismo cliente puede comprar en dos tiendas y no debe contarse dos veces; hay que recalcularlo a cada nivel de agregación.

8.3. Media simple de porcentajes: 20,0 %. Recalculado: $99.600 / 600.000 = 16,6 \%$. Para un comité: «el 20 % trata igual a Valencia, que hace dos tercios de la facturación, que a Vigo, que hace el 3 %. Las tiendas pequeñas tienen más margen porcentual y arrastran la media hacia arriba».

8.4. Jerarquía comercial: Sección → Familia → Subfamilia → Artículo, que responde a «¿qué categorías tiran del margen?». Jerarquía de proveedor: Proveedor → Marca → Artículo, que responde a «¿qué proveedores nos aportan más margen y cuál es nuestra dependencia de cada uno?».

8.5. Sumar el stock de los treinta días da un número sin significado. La agregación correcta por la dimensión tiempo es el último valor del período —el stock a fin de mes— o la media diaria, según se quiera medir la posición final o la inmovilización media.

8.6. Con tipo 1, todas las ventas del año aparecen en la región nueva, incluidas las anteriores al cambio. Con tipo 2, las anteriores quedan en la región antigua. La «correcta» depende de la pregunta: para evaluar el rendimiento histórico de la región antigua, tipo 2; para planificar con la estructura actual, hace falta además el atributo de región vigente. Lo habitual es implementar ambos.

Capítulo 9 · Analizar

9.1. Primero por familia de producto, porque el ticket medio es muy sensible al mix y es la causa más frecuente. Después por tienda, para descartar que sea un efecto local. Después por canal, porque la web tiene un ticket estructuralmente distinto. Y por último por segmento de cliente. El orden va de la causa más probable a la menos.

9.2. (a) A causa B: la acumulación del fin de semana satura el taller el lunes. (b) B causa A: se reserva el lunes para los trabajos que se sabe que son largos. (c) Confusión: los lunes entran más restauraciones porque el cliente las trae tras usar la bici el fin de semana, y son largas por su naturaleza. Para distinguir, hace falta el tipo de trabajo y la carga del taller por día.

9.3. No. Ambas pueden estar causadas por el mismo factor: la compra de una bicicleta nueva, que arrastra ropa y casco a la vez. La prueba sería un experimento: promocionar cascos en seis tiendas elegidas al azar y no en las otras seis, y comparar la venta de ropa entre ambos grupos.

9.4. Respuesta abierta. La construcción funciona repartiendo desigualmente los casos entre dos grupos con tasas base muy distintas.

9.5. (1) Las tiendas que abren en domingo pueden ser las de zonas comerciales, con más tráfico de por sí. (2) Puede haber desplazamiento de venta desde el sábado, no venta adicional. (3) El coste laboral del domingo puede consumir el margen extra. (4) La comparación no controla el tamaño ni la antigüedad de las tiendas. Es un caso de poblaciones no equivalentes.

Capítulo 10 · Minería de datos

10.1. (a) Clasificación. (b) Agrupamiento. (c) Reglas de asociación. (d) Regresión. (e) Detección de anomalías.

10.2. Fuga de información: la variable «número de llamadas de aviso de retraso» sólo existe **después** de que el retraso se haya producido. En el momento en que hay que predecir vale siempre cero. El modelo no predice nada; describe el pasado.

10.3. Criterio estadístico: que los grupos sean compactos y estén separados, y que la solución sea estable al repetir el algoritmo con otra muestra o semilla. Criterio de negocio: que cada grupo se pueda describir en una frase y que sugiera una acción comercial distinta. Si dos grupos merecen la misma acción, sobran grupos.

10.4. Porque el reparto aleatorio permitiría entrenar con datos posteriores a los de prueba, lo que en producción es imposible. La alternativa es la partición temporal: entrenar con los primeros períodos y validar con los últimos, avanzando la ventana.

10.5. (1) ¿Qué decisión concreta va a mejorar este proyecto y quién la toma? (2) ¿Cómo sabremos dentro de seis meses si ha servido para algo? (3) ¿Qué se hace hoy para tomar esa decisión y qué tiene de insuficiente?

Capítulo 11 · Indicadores y cuadros de mando

11.1. Ejemplo: Nombre — tasa de devolución. Pregunta — ¿qué proporción de lo vendido se devuelve? Fórmula — $\text{importe devuelto} / \text{importe vendido}$. Fuente — HECHO_VENTAS, capa de presentación. Grano — línea de ticket. Filtros — excluye traspasos y ventas a empleados. Período — la devolución se imputa al mes de la venta original, para que el indicador sea comparable. Responsable — dirección comercial.

11.2. Dos señales bastan sin ver el detalle: que el valor de la cadena esté fuera del rango de valores de las tiendas —imposible en una agregación correcta— o que el indicador cambie al aplicar un filtro que no debería afectarle. Con tiendas entre el 15 % y el 25 %, un 20 % es posible, pero se puede comprobar recalculando desde los totales de margen y venta.

11.3. Mediana del ticket, porque describe al cliente típico; P90, porque identifica la venta grande; y número de tickets, porque sin volumen el ticket medio no se puede interpretar. La media se muestra en segundo plano.

11.4. KPI: tasa de conversión, margen por familia, porcentaje de reparaciones fuera de plazo —los tres tienen responsable, objetivo y acción asociada. Decoración: número de visitas a la web (sin conversión no cambia ninguna decisión), seguidores en redes, número de referencias en catálogo.

11.5. Da la impresión de una variación enorme entre meses cuando es del 6 %. En un gráfico de barras el eje debe empezar en cero, porque la longitud de la barra codifica la magnitud. Si lo que interesa es la variación, se cambia a un gráfico de líneas indicando el rango.

11.6. Ejemplo: mide el número de órdenes que superan el plazo comprometido. Umbral: más de 2σ sobre la media de las últimas ocho semanas. Avisa al jefe de taller. Acción: reasignar carga o comunicar el retraso al cliente. Es mejor que un número fijo porque se adapta a la estacionalidad: en julio la carga normal es el triple que en enero, y un umbral fijo dispararía todos los días de verano.

Capítulo 12 · Series temporales y pronósticos

12.1. (1) Comprobar la comparación interanual: en un negocio estacional, la caída de octubre respecto a septiembre es normal. (2) Comprobar si la variación está dentro del ruido histórico ($\pm 7\%$); una caída del 28% lo supera, luego es real. (3) Comprobar que la carga de datos está completa antes de buscar explicaciones de negocio.

12.2. Mensual: movimiento inmediato, inútil en negocio estacional. Interanual: crecimiento real. Acumulado: avance hacia el objetivo anual. Media móvil: tendencia de fondo. Ante el comité se llevan interanual y acumulado; la media móvil como apoyo si se está discutiendo un cambio de tendencia.

12.3. Se necesitan las ventas de cascos del mismo trimestre del año anterior y una comprobación de que ese trimestre no fue anómalo. El resultado se usa como referencia: cualquier modelo más sofisticado debe batir su error, y si no lo bate, no se adopta.

12.4. Respuesta abierta. Debe contener el valor esperado, un intervalo con su nivel de confianza y los supuestos explícitos.

12.5. No es casualidad: los grupos pequeños tienen más varianza y por eso ocupan los extremos de cualquier ranking. Se comprueba viendo si las tres últimas posiciones también son tiendas pequeñas. Se corrige mostrando el tamaño de la muestra, ocultando los grupos por debajo de un mínimo, o representando el intervalo de cada valor en lugar del punto.

12.6. (1) Cambio de régimen: algo cambió en el negocio. (2) Degradación normal: el modelo necesita reentrenarse. (3) Problema de calidad en los datos de entrada. (4) Realimentación: el modelo está prediciendo su propia decisión. Se distinguen mirando si la caída fue brusca o gradual, si coincide con un cambio conocido, y si los datos de entrada mantienen su distribución histórica.

Capítulo 13 · Gestión del proyecto

13.1. Ejemplo: «Que el comité de dirección pueda decidir, cada trimestre y con datos que las doce tiendas reconozcan como suyos, dónde invertir en superficie y plantilla. Responsable: dirección general. Se medirá por el uso semanal del cuadro de mando y por que la cifra de venta coincida con el cierre contable.»

13.2. Respuesta abierta; debe coincidir en lo esencial con la tabla del apartado 15.2. Las dependencias críticas son el acceso a los doce TPV y la disponibilidad de la persona que mantiene `Objetivos.xlsx`.

13.3. El reparto está invertido: dedica el 62% a cuadros de mando y el 25% a análisis y datos. Propuesta: dos semanas de definición y acuerdo de KPIs, dos de perfilado y calidad, dos y media de

procesos de carga, una de cuadros de mando y media de validación. Y admitir que ocho semanas para seis fuentes es optimista.

13.4. Ejemplo verificable: «los doce responsables de tienda han validado que la cifra de venta neta de su tienda coincide con su cierre de caja del último mes, y ocho de los doce han abierto el cuadro al menos una vez en la última semana».

13.5. Respuesta abierta. Ejemplos: para la calidad, control de volumen y rango en la carga; para las definiciones divergentes, prueba automática que compare la venta del cuadro con el dato contable; para el cuadro que nadie usa, registro de accesos con alerta si una tienda no entra en dos semanas.

Parte II · El caso

II.1. El número de clientes estaba inflado en un 44 %; la venta media por cliente estaba subestimada en un 31 %; el porcentaje de clientes recurrentes estaba subestimado a menos de la mitad. Los tres errores empujaban en la misma dirección: hacían parecer que la empresa captaba mucho y fidelizaba poco.

II.2. Supóngase que hay 100 reparaciones cerradas con media de 2 días y 10 abiertas que llevan ya 15 días. Con sólo las cerradas, el tiempo medio publicado es de 2 días. Incorporando las abiertas con su duración hasta hoy, la media sube a 3,2. El sesgo es sistemático y siempre a la baja, porque las que más tardan son las que todavía no han cerrado.

II.3. A favor: 2,6 puntos de error sobre una previsión de 148.000 € son unos 3.800 € de desviación menos, y el modelo se automatiza. En contra: añade una dependencia técnica y un mantenimiento, y el ingenuo estacional lo entiende cualquiera. Defendible en ambos sentidos; lo importante es que la dirección decida sabiendo cuánto compra.

II.4. Comparar el número de órdenes cargadas con la media de las últimas cuatro ejecuciones y marcar la carga como incompleta si se desvía más de 2σ . Añadir una regla de validación de caracteres en los campos de texto libre y un informe de registros rechazados que no se pueda quedar vacío en silencio.

II.5. (1) Registro de accesos: cuándo entran, a qué páginas, cuánto tiempo. (2) Entrevistas con los cuatro responsables, sin la presencia de dirección. (3) Observación directa de cómo resuelven hoy las decisiones que el cuadro debía soportar. La hipótesis más probable es que el cuadro operativo resuelve algo que no era un problema para ellos.

II.6. Respuesta abierta. Debe contener: qué se calculaba mal y por qué (promedio de porcentajes en lugar de recálculo desde totales), la magnitud (3,4 puntos), qué decisiones se apoyaron en él, qué se ha corregido y qué control impide que vuelva a pasar. Sin atribuir culpa individual: es un error de método, y el método era el mismo en toda la organización.

Apéndice E · Errores que circulan como verdades

Recopilación de afirmaciones que se oyen con frecuencia en entornos de BI, y que son falsas o incompletas.

E.1. «Media ± 1 desviación típica contiene al menos el 50 % de los casos»

Falso. La desigualdad de Chebyshev garantiza al menos $1 - 1/k^2$, que para $k = 1$ da cero: no garantiza nada. El 68 % que mucha gente recuerda pertenece a la regla empírica y **exige que la distribución sea aproximadamente normal**.

La afirmación segura, válida sea cual sea la distribución, es: **media $\pm 2\sigma$ contiene al menos el 75 %**. Y es más útil, porque conecta directamente con la detección de atípicos.

E.2. «Los valores atípicos se eliminan para que no distorsionen»

Incompleto y peligroso. Sólo se elimina un atípico si se ha comprobado que es un error de dato. Si es real, se conserva y con frecuencia se estudia aparte: en detección de fraude, mantenimiento predictivo y análisis de rentabilidad, el atípico es precisamente el objeto de estudio.

E.3. «La media es el indicador más representativo»

Falso en distribuciones asimétricas, que son la mayoría en negocio: importes, salarios, tiempos de espera y valor de cliente son casi siempre asimétricos positivos. En esos casos la mediana representa mejor al colectivo, y ninguno de los dos basta por sí solo.

E.4. «Se puede calcular la media de una valoración de 1 a 10»

Discutible. Es una escala ordinal sin unidad de medida: no hay garantía de que la distancia entre 3 y 4 sea la misma que entre 8 y 9, ni de que el 7 de una persona equivalga al de otra. Se hace en todas partes; lo que no se puede omitir es publicar la distribución al lado.

E.5. «El margen de la cadena es la media de los márgenes de las tiendas»

Falso. Los ratios no se promedian: se recalculan desde los totales, o se ponderan por el volumen. En el ejemplo del capítulo 8, la diferencia es de 3,4 puntos porcentuales sobre el indicador que fija la política de precios.

E.6. «Si dos variables están correlacionadas, una causa la otra»

Falso. Hay cuatro explicaciones posibles y sólo una es la causalidad directa. La más frecuente en negocio es la variable de confusión. Para afirmar causalidad hace falta precedencia temporal, asociación

y descarte de explicaciones alternativas; idealmente, un experimento controlado.

E.7. «Con un data lake ya no hace falta transformar los datos»

Falso. El cambio de ETL a ELT modifica **dónde** se transforma, no **si** hay que transformar. Un depósito de ficheros sin limpiar, conformar ni documentar no es un data lake: es un almacén de datos que nadie sabe interpretar.

E.8. «Un modelo con 99 % de acierto es un buen modelo»

Casi siempre falso. O hay sobreajuste, o hay fuga de información, o las clases están tan desequilibradas que predecir siempre lo mismo produce ese acierto. Con un 2 % de bajas, un modelo que diga «nadie se da de baja» acierta el 98 % y es inútil.

E.9. «El dato en tiempo real siempre es mejor»

Falso en la mayoría de los casos. La latencia debe fijarse por la frecuencia de la decisión, no por la capacidad técnica. Si la decisión se toma en el comité mensual, un dato al minuto no aporta nada y multiplica el coste y la fragilidad. El tiempo real se justifica en decisiones operativas: stock, fraude, incidencias.

E.10. «Las devoluciones se restan del mes en que ocurren»

No es un error, es una decisión —pero hay que tomarla explícitamente y por escrito. Cada opción tiene consecuencias distintas sobre la comparabilidad y sobre la volatilidad de los meses ya cerrados. Lo inaceptable es que dos informes usen criterios distintos sin que nadie lo sepa.

E.11. «Un porcentaje de variación siempre es interpretable»

Falso cuando la base puede ser cero o negativa. Si el margen del año anterior fue negativo, el porcentaje de variación no tiene interpretación. Y con bases pequeñas, pasar de 1 a 3 ventas es un +200 % que no significa nada sin el valor absoluto al lado.

E.12. «Si el cuadro de mando está publicado, el proyecto ha terminado»

Falso. El valor de un proyecto de BI está en el uso, no en el entregable. Un cuadro que nadie abre es un proyecto fracasado aunque cumpliera plazo y presupuesto. El uso se mide, y es el indicador de éxito más fiable que existe.
